可以先看以下這兩個方向 覺得是很好的切入點

A. Closed / Open source models - 3. Open or Closed / 4. Kimi is hot

B. AI community - 4. 從成本看AI**Bubble 0703 ~10/26**

大家有什麼**comment or** 對於**user story** 有想法也可以直接留在這裡 我有找到相關的東西可以直接貼在這裡回覆

1. Nebius increase H100 leasing price 9/18

AI 折舊論遭打臉？Nebius 傳再漲價、連 H100 也漲租

September 18, 2026 by MoneyDJ Tagged: AI 晶片, Nebius, 租金, 輝達
Categories: AI 人工智慧, GPU, Nvidia, 晶片

Z9 的看板
9月18日 ·

需求真旺!! 但基礎建設新產能要等到明年底才有
--
市場傳出，荷蘭 AI 基礎建設供應商 Nebius Group 近期通知客戶，將調高一系列 AI 晶片的隨需租用價格（on-demand rental prices），其中多款輝達（Nvidia Corp.）繪圖處理器（GPU）的租金將上漲約 20%。

綜合Barron's、路透社等外電報導，Futurum Equities首席市場策略師Shay Boloor 17日透過社交平台X指出，Nebius宣布，自10月1日起調高隨需GPU租用價格，輝達旗下H100、H200、B200與B300的費率均上漲約20%。

其中，B300漲幅最大，每GPU小時租金將從7.85美元調高至9.50美元。與此同時，Nebius也持續擴大在歐洲與美國的GPU供應量。
..... 查看更多

11 1

最相關

Z9 的看板 · 5週 · 作者
https://technews.tw/...../nebius-hikes-ai-cloud...../

TECHNEWS.TW
AI 折舊論遭打臉？Nebius 傳...

留言.....

2. A100 leasing price still increasing 10/24

cheese_bash 1h

GPU 仍沒有按照原有標準的 6 年折舊速度出租，比原有預計出租的價格高出至少 50 至 140%（除了 A100 是高出大約 9%）。

現在卡在瓶頸的不是卡，是有沒有足夠的電及基建，有電便能把卡變作算力變現。

另外 Elon Musk 亦十分隱晦地回應了為何租值沒有如期下降：
你想僱用多少超聰明且盡責的人？

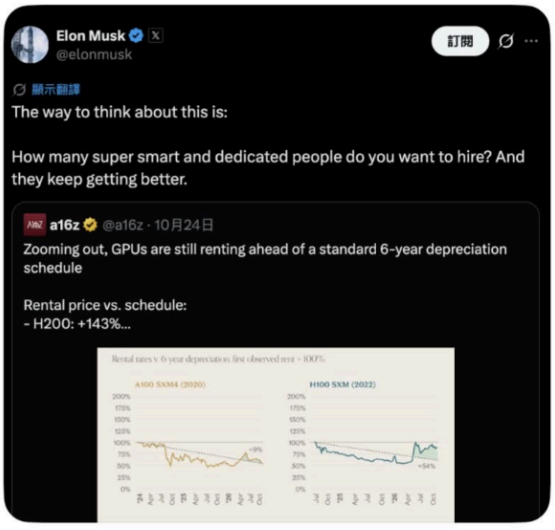

Elon Musk
@elonmusk
訂閱

顯示翻譯
The way to think about this is:

How many super smart and dedicated people do you want to hire? And they keep getting better.

a16z @a16z · 10月24日
Zooming out, GPUs are still renting ahead of a standard 6-year depreciation schedule

Rental price vs. schedule:
- H200: +143%...

3. Corweave FCF and Debt issue 10/24

4. RTX 3090 leasing price is increasing

5. A100 and H100 is still in high demand 09/08

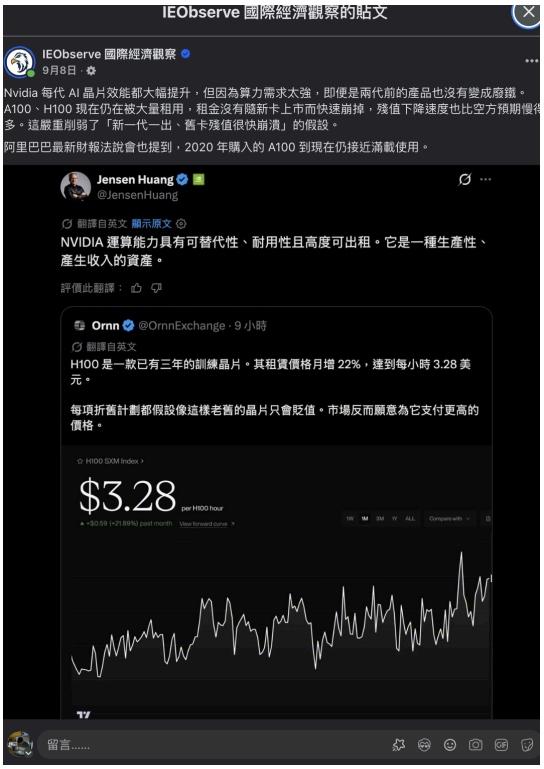

6. The need of Nvidia GPU fopr training models 09/07

7. Corweave / Nebius stock price 07/31

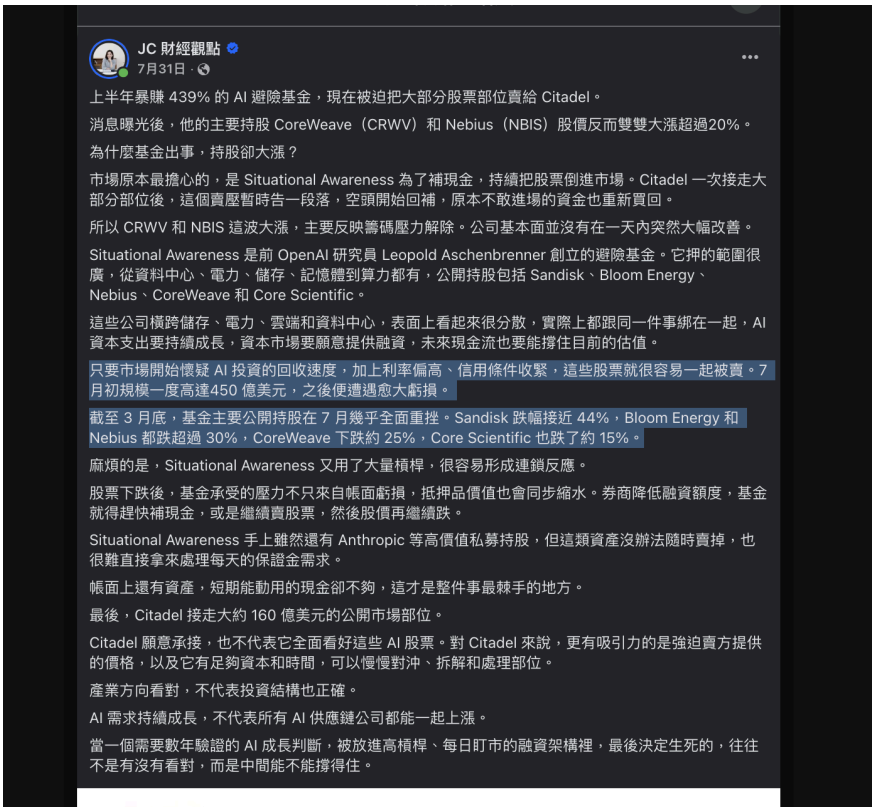

JC 財經觀點
7月31日 ·

上半年暴賺 439% 的 AI 避險基金，現在被迫把大部分股票部位賣給 Citadel。

消息曝光後，他的主要持股 CoreWeave（CRWV）和 Nebius（NBIS）股價反而雙雙大漲超過20%。

為什麼基金出事，持股卻大漲？

市場原本最擔心的，是 Situational Awareness 為了補現金，持續把股票倒進市場。Citadel 一次接走大部分部位後，這個賣壓暫時告一段落，空頭開始回補，原本不敢進場的資金也重新買回。

所以 CRWV 和 NBIS 這波大漲，主要反映籌碼壓力解除。公司基本面並沒有在一天內突然大幅改善。

Situational Awareness 是前 OpenAI 研究員 Leopold Aschenbrenner 創立的避險基金。它押的範圍很廣，從資料中心、電力、儲存、記憶體到算力都有，公開持股包括 Sandisk、Bloom Energy、Nebius、CoreWeave 和 Core Scientific。

這些公司橫跨儲存、電力、雲端和資料中心，表面上看起來很分散，實際上都跟同一件事綁在一起，AI 資本支出要持續成長，資本市場要願意提供融資，未來現金流也要能撐住目前的估值。

只要市場開始懷疑 AI 投資的回收速度，加上利率偏高、信用條件收緊，這些股票就很容易一起被賣。7 月初規模一度高達450 億美元，之後便遭遇愈大虧損。

截至 3 月底，基金主要公開持股在 7 月幾乎全面重挫。Sandisk 跌幅接近 44%，Bloom Energy 和 Nebius 都跌超過 30%，CoreWeave 下跌約 25%，Core Scientific 也跌了約 15%。

麻煩的是，Situational Awareness 又用了大量槓桿，很容易形成連鎖反應。

股票下跌後，基金承受的壓力不只來自帳面虧損，抵押品價值也會同步縮水。券商降低融資額度，基金就得趕快補現金，或是繼續賣股票，然後股價再繼續跌。

Situational Awareness 手上雖然還有 Anthropic 等高價值私募持股，但這類資產沒辦法隨時賣掉，也很難直接拿來處理每天的保證金需求。

帳面上還有資產，短期能動用的現金卻不夠，這才是整件事最棘手的地方。

最後，Citadel 接走大約 160 億美元的公開市場部位。

Citadel 願意承接，也不代表它全面看好這些 AI 股票。對 Citadel 來說，更有吸引力的是強迫賣方提供的價格，以及它有足夠資本和時間，可以慢慢對沖、拆解和處理部位。

產業方向看對，不代表投資結構也正確。

AI 需求持續成長，不代表所有 AI 供應鏈公司都能一起上漲。

當一個需要數年驗證的 AI 成長判斷，被放進高槓桿、每日盯市的融資架構裡，最後決定生死的，往往不是有沒有看對，而是中間能不能撐得住。

8. Azure 算力跳升07/16

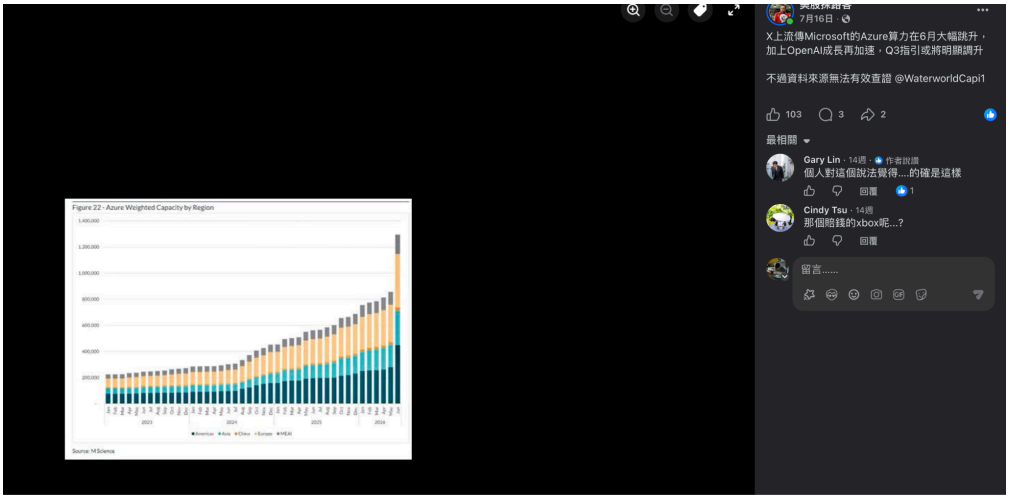

9. All rise due to old gpus and B200s still unavailable 0703

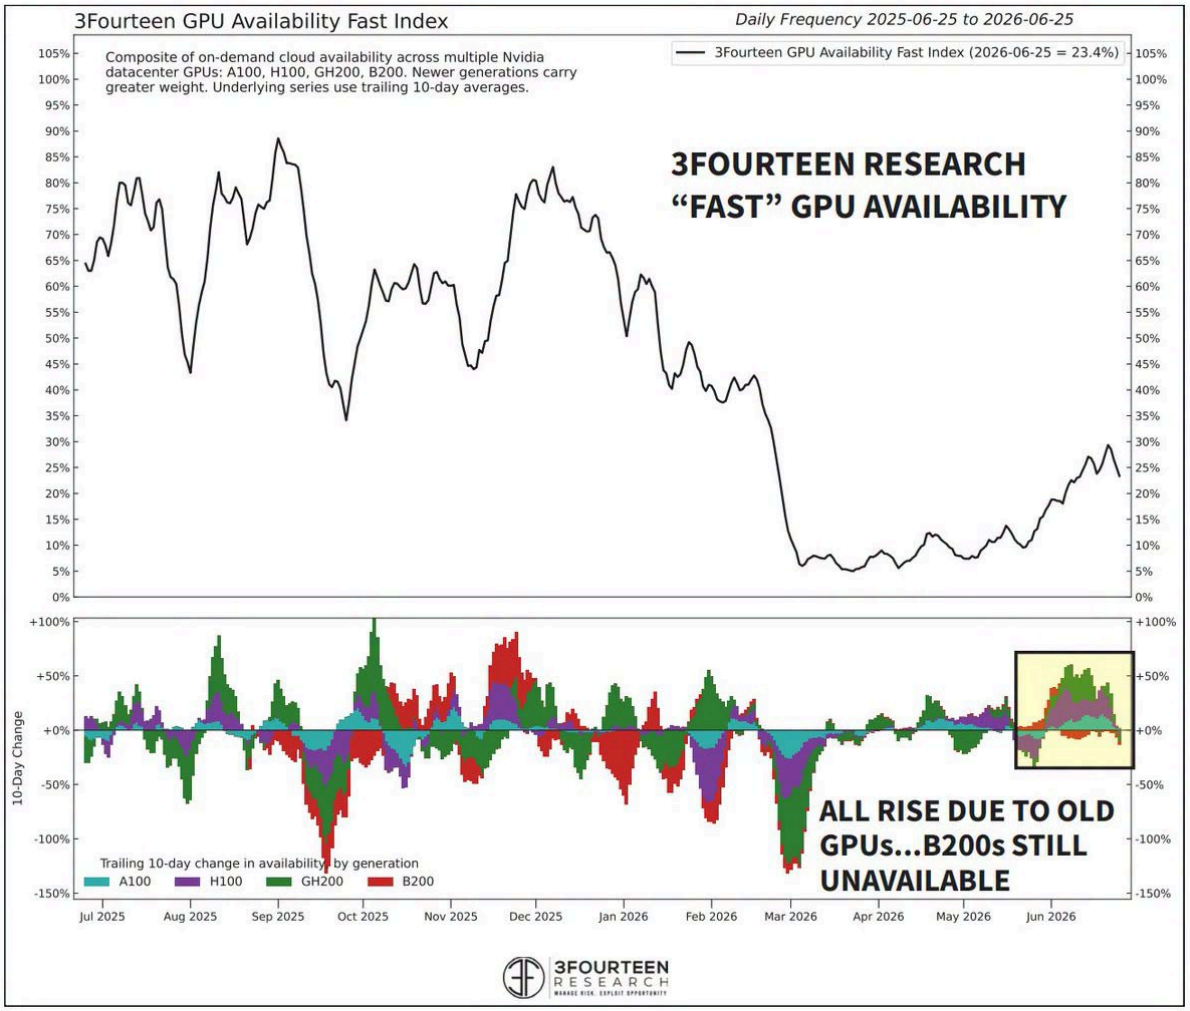

10. Meta sold their additional gpus 0701

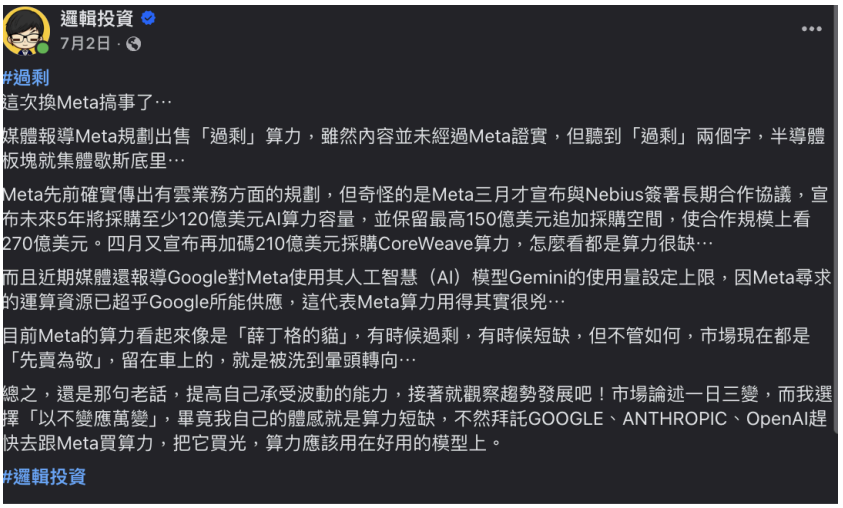

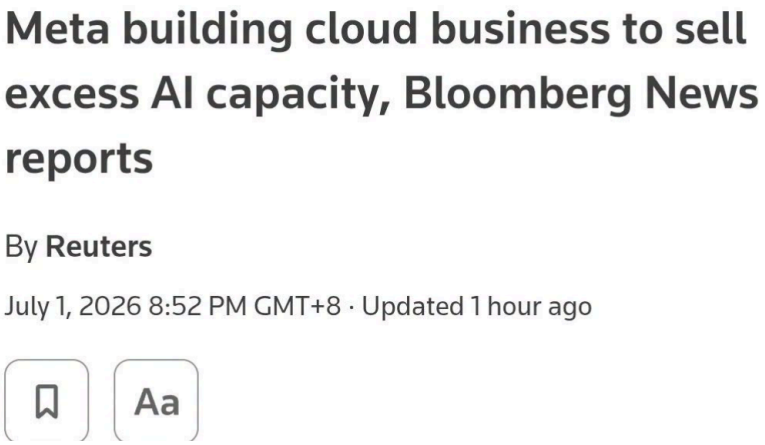

11. leasing price is decreasong 0625

最近AI圈又有大新聞了，就是算力租金的價格崩盤了！

要知道兩個月前，全球AI公司還為了搶算力把GPU的租賃價格炒高了40%

但如今NVIDIA B200 GPU的租賃價格已經從6.11美元/小時下跌到如今的4.22美元/小時。

雖然租金價格下跌不意味著NVIDIA晶片需求放緩，但投資人似乎開始將資金從輝達撤出，轉而投資產品售價漲勢更兇猛的記憶體。

6月至今，輝達股價下跌4%、記憶體如美光卻大漲15%

這也告訴我們，雖然同樣很夯、同樣受惠於AI，但不同產品企業間也是競爭對手。

對於投資人來說，我們不能只看『某個產業受惠』就去投資某個產業。

因為這些企業之間也是會搶奪資金的！

A企業成長80%、B企業成長50%、C企業成長30%
那股價的漲幅不會是80%、50%、30%

很可能是A股價翻倍、B股價上漲10%、C股價不漲反跌

因為資金都只會去追尋最強的標的。

至於B、C企業是否會補漲？何時會補漲？這都是不確定的！

高盛交易部主管Rich Privorotsky就表示，當市場都在炒作AI基礎建設時，這些『有可能受惠的企業』都會受到資金青睞，股價上漲，這時這些企業並沒有任何基本面的改變。

12. Janestreet invest Coreweave 0416

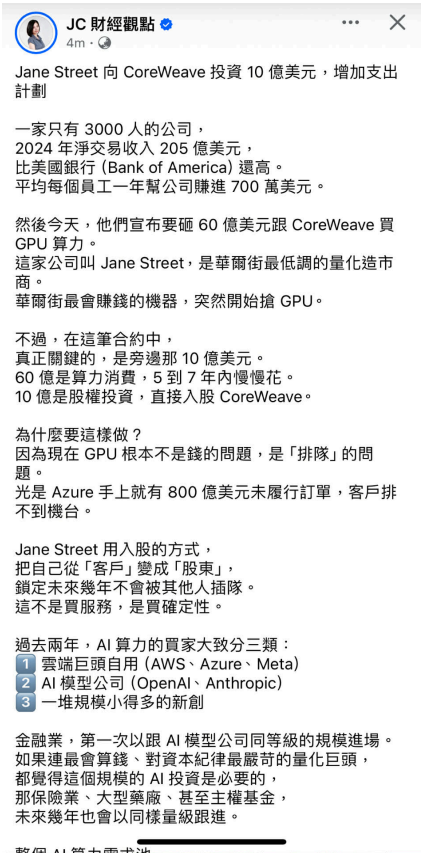

JC 財經觀點
4m ·

Jane Street 向 CoreWeave 投資 10 億美元，增加支出計劃

一家只有 3000 人的公司，
2024 年淨交易收入 205 億美元，
比美國銀行 (Bank of America) 還高。
平均每個員工一年幫公司賺進 700 萬美元。

然後今天，他們宣布要砸 60 億美元跟 CoreWeave 買 GPU 算力。
這家公司叫 Jane Street，是華爾街最低調的量化造市商。
華爾街最會賺錢的機器，突然開始搶 GPU。

不過，在這筆合約中，
真正關鍵的，是旁邊那 10 億美元。
60 億是算力消費，5 到 7 年內慢慢花。
10 億是股權投資，直接入股 CoreWeave。

為什麼要這樣做？
因為現在 GPU 根本不是錢的問題，是「排隊」的問題。
光是 Azure 手上就有 800 億美元未履行訂單，客戶排不到機台。

Jane Street 用入股的方式，
把自己從「客戶」變成「股東」，
鎖定未來幾年不會被其他人插隊。
這不是買服務，是買確定性。

過去兩年，AI 算力的買家大致分三類：
1 雲端巨頭自用 (AWS、Azure、Meta)
2 AI 模型公司 (OpenAI、Anthropic)
3 一堆規模小得多的新創

金融業，第一次以跟 AI 模型公司同等級的規模進場。
如果連最會算錢、對資本紀律最嚴苛的量化巨頭，
都覺得這個規模的 AI 投資是必要的，
那保險業、大型藥廠、甚至主權基金，
未來幾年也會以同樣量級跟進。

13.

andrew_hwy › 股票投資 12h

外行看熱鬧，內行看門道。
那是因為明年 2027 MSFT 的 3nm MAIA 自研 ASIC 還有 CPU Cobolt 比今年成長 4-5 倍。

Bloomberg

EXCLUSIVE Technology | AI

微軟正逐步終止與甲骨文的AI雲端容量租約

紐約的一棟微軟大樓。 攝影：邁克爾納格爾/彭博社

By Brody Ford
November 7, 2026 at 1:36 AM GMT+8

1. GPU and CPU demand 10/9

1 萬次瀏覽

orion__06666 2026-10-9

CPU !!!
摩根大通：我們的技術研究團隊強調，傳統大型語言模型基礎設施採用以 GPU 為主的架構，CPU/GPU 比例為 1:4 至 1:8。對於代理式 AI，該比例將轉向 1:1，甚至可能變得更偏向 CPU，因為代理會產生更多協調、資料移動、工具使用以及狀態管理的工作負載。

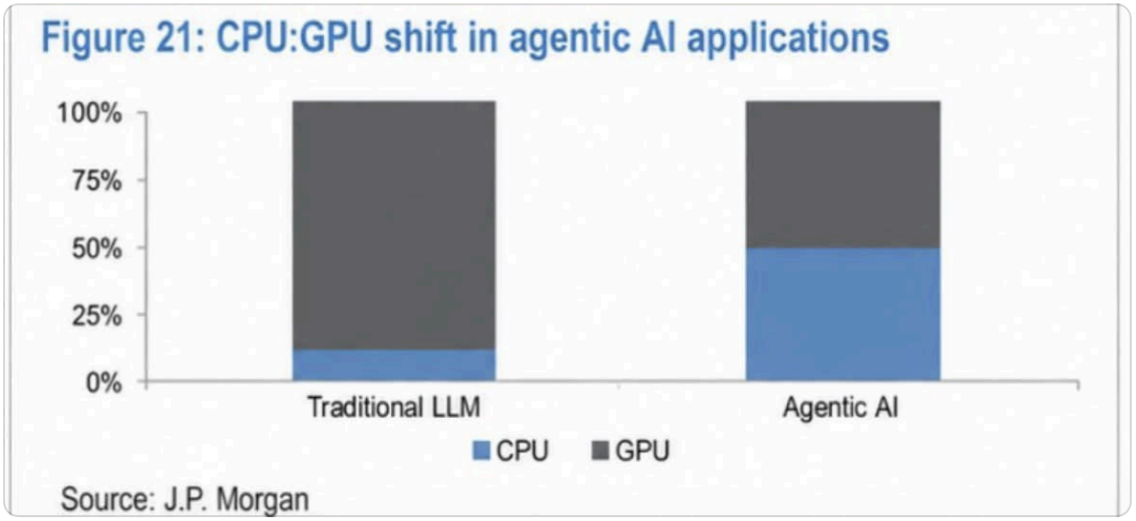

2. Muse need 158 M CPU 09/25

3. Need for CPU

1. Chatgpt lead 9/23

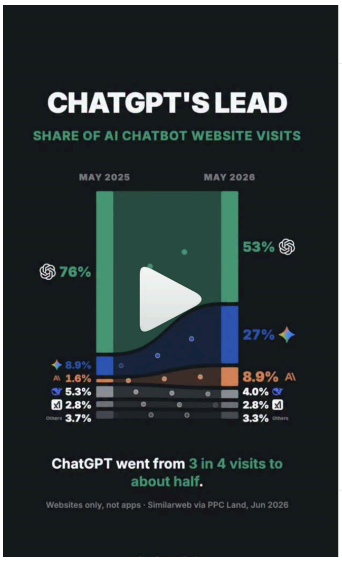

greenowl.markets · 追蹤
veneris • Vivaldi Winter Drill #2

greenowl.markets 4週
A year ago, 3 of every 4 visits to an AI chatbot website went to ChatGPT. Now it's about half. Here's where they went.

Share of visits to the seven biggest AI chatbot websites, May 2025 vs May 2026 (Similarweb).

One thing the chart doesn't show: ChatGPT didn't lose visitors. Its visits were roughly flat year over year; the others grew around it, so its slice shrank.

Also: this counts website visits only. Phone apps aren't included, and ChatGPT's app is huge, so its real reach is bigger than this.

Not financial advice.

416 9

9月23日

2. Opus 5.5 vs Astra: 9/23

哈利說
9月23日 ·

今天兩個重點模型推出，速記一下：

Claude Opus 5.5
- 跟 Fable 5.1 差不多的智能，但是單看 token 價格是便宜 60%
- 跟 Astra 比也是 token 便宜 60%，但 Astra 的 token efficiency 仍然比 Opus 5.5 高出許多，所以實際使用下來 Opus 5.5 有時候還會比 Astra 更貴
- Anthropic 這次有特別強調 Opus 5.5 的 3D 空間理解能力，似乎想來挫 Astra 的銳氣
- 發表的時候很強調「這是我們要 pace the frontier 之後的第一個模型」，意思就是說「我們這個模型沒有要推進能力前沿，而是把目前的前沿做得更便宜好用」

GPT-6 Sol & Luna
- 智能說是有提升，但是從 benchmark 上初步看起來不是很明顯（當然還是要實測）
- 主要的亮點應該是成本降低，token 價格直接砍半

475 10 14

3. Anthropic strategic business plan 10/26

游庭皓的財經皓角
20分鐘 ·

Anthropic營收越來越依賴熟客。根據YipitData統計，2026年初以來，支出排名前1%的客戶，平均每月支付金額從約30萬美元，暴增至8月的285萬美元，成長接近9倍，中位數也從約25萬美元攀升至220萬美元。

相較之下，這群頂級客戶占整體客戶支出的比重，則從2025年初約25%，提高至2026年8月的45%左右。

這代表Anthropic的營收成長，卻愈來愈仰賴少數高用量企業持續擴大AI預算，雖然有利於快速提升營收規模，但也意味著客戶集中度，與大型企業削減支出的風險正在增加。 顯示較少

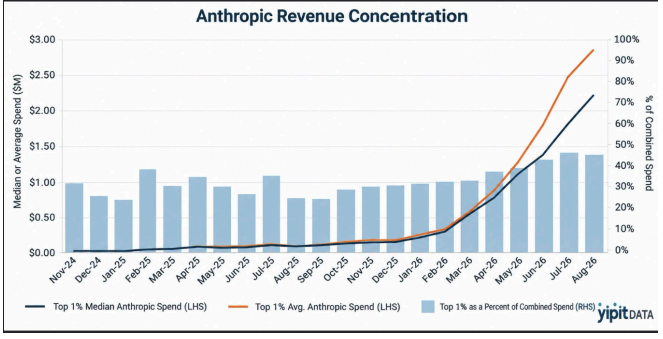

4. Token Usagefor B2B 10/26

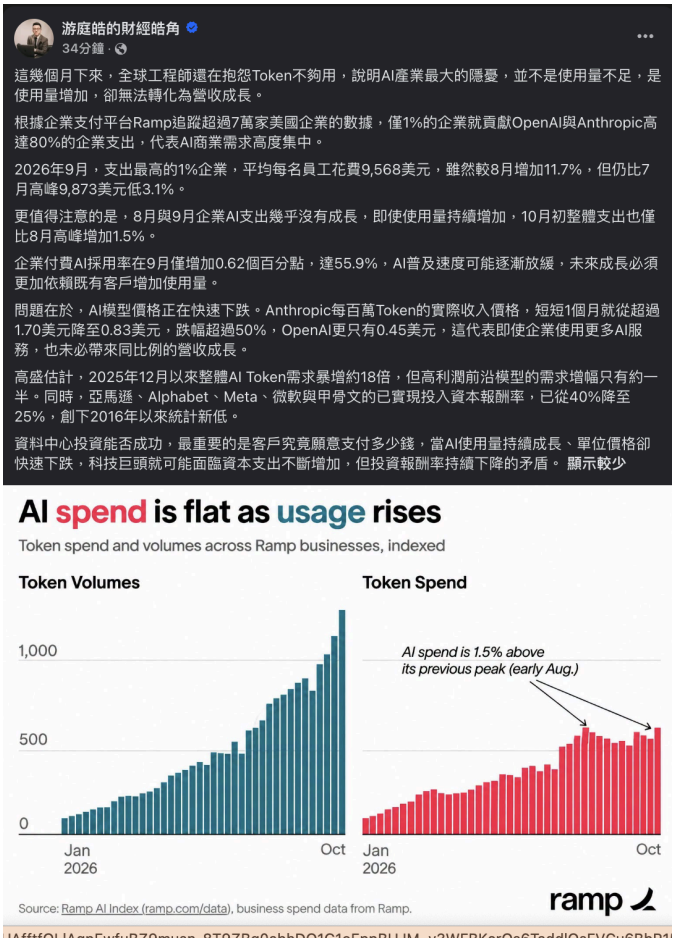

游庭皓的財經皓角
34分鐘 ·

這幾個月下來，全球工程師還在抱怨Token不夠用，說明AI產業最大的隱憂，並不是使用量不足，是使用量增加，卻無法轉化為營收成長。

根據企業支付平台Ramp追蹤超過7萬家美國企業的數據，僅1%的企業就貢獻OpenAI與Anthropic高達80%的企業支出，代表AI商業需求高度集中。

2026年9月，支出最高的1%企業，平均每名員工花費9,568美元，雖然較8月增加11.7%，但仍比7月高峰9,873美元低3.1%。

更值得注意的是，8月與9月企業AI支出幾乎沒有成長，即使使用量持續增加，10月初整體支出也僅比8月高峰增加1.5%。

企業付費AI採用率在9月僅增加0.62個百分點，達55.9%，AI普及速度可能逐漸放緩，未來成長必須更加依賴既有客戶增加使用量。

問題在於，AI模型價格正在快速下跌。Anthropic每百萬Token的實際收入價格，短短1個月就從超過1.70美元降至0.83美元，跌幅超過50%，OpenAI更只有0.45美元，這代表即使企業使用更多AI服務，也未必帶來同比例的營收成長。

高盛估計，2025年12月以來整體AI Token需求暴增約18倍，但高利潤前沿模型的需求增幅只有約一半。同時，亞馬遜、Alphabet、Meta、微軟與甲骨文的已實現投入資本報酬率，已從40%降至25%，創下2016年以來統計新低。

資料中心投資能否成功，最重要的是客戶究竟願意支付多少錢，當AI使用量持續成長、單位價格卻快速下跌，科技巨頭就可能面臨資本支出不斷增加，但投資報酬率持續下降的矛盾。 顯示較少

5. Open AI is winning 9/17

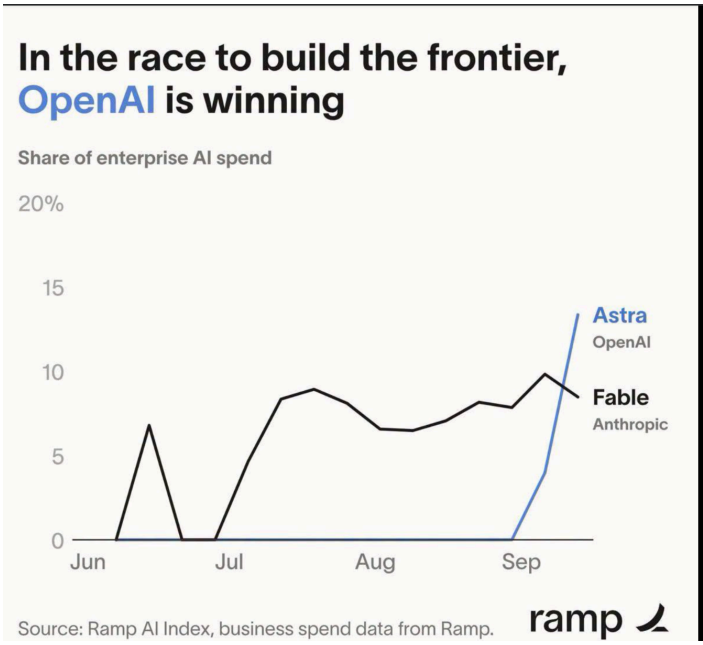

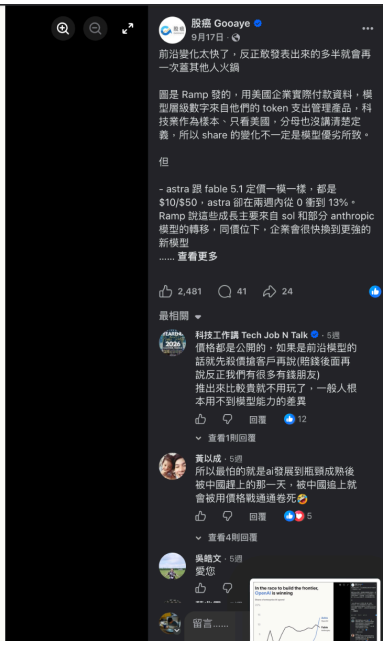

股癌 Gooaye
9月17日 ·
前沿變化太快了，反正敢發表出來的多半就會再一次蓋其他人火鍋

圖是 Ramp 發的，用美國企業實際付款資料，模型層級數字來自他們的 token 支出管理產品，科技業作為樣本、只看美國，分母也沒講清楚定義，所以 share 的變化不一定是模型優劣所致。

但

- astra 跟 fable 5.1 定價一模一樣，都是 $10/$50，astra 卻在兩週內從 0 衝到 13%。Ramp 說這些成長主要來自 sol 和部分 anthropic 模型的轉移，同價位下，企業會很快換到更強的新模型
..... 查看更多

2,481 41 24

最相關

科技工作講 Tech Job N Talk · 5週
價格都是公開的，如果是前沿模型的話就先殺價搶客戶再說(賠錢後面再說反正我們有很多有錢朋友)
推出來比較貴就不用玩了，一般人根本用不到模型能力的差異
回覆 12
查看1則回覆

黃以成 · 5週
所以最怕的就是ai發展到瓶頸成熟後被中國趕上的那一天，被中國搶上就會被用價格戰通通卷死🤣
回覆 5
查看4則回覆

吳曉文 · 5週
愛您

6. Anthropic B2B is still in low adoption 8/27

7. Estimated revenue from frontier AI providers 08/20

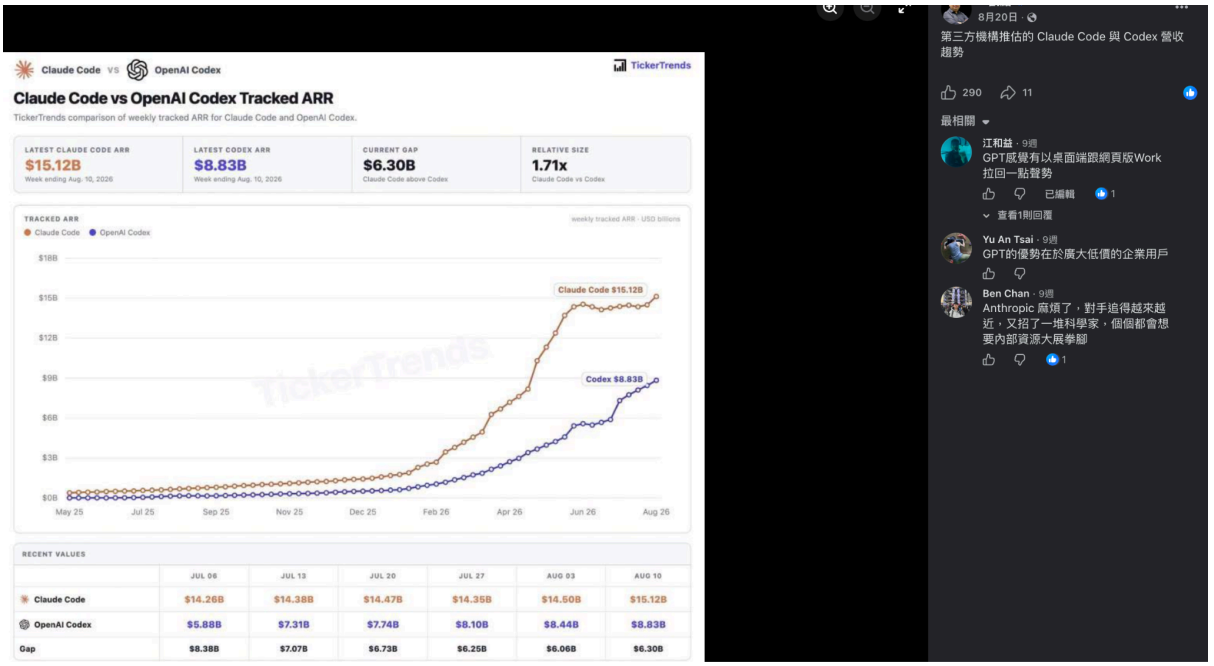

8. AI race from 2024 to now 7/27

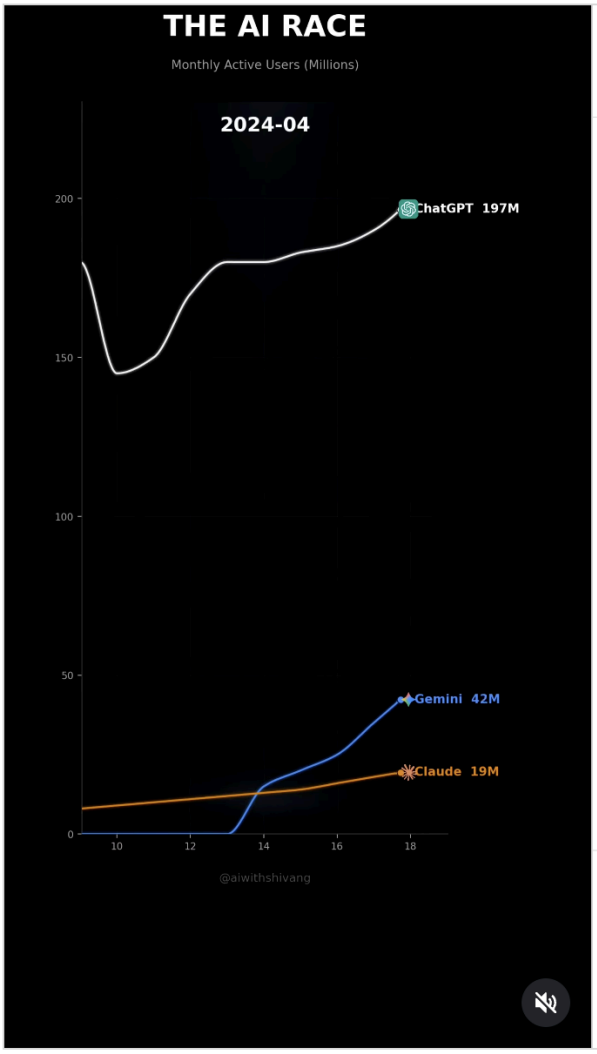

aiwithshivang • 追蹤
1HXSX, wnorg17 • REVENGE (Super Slowed)

aiwithshivang 12週
I created this video with Python Code and just a CSV Data File. No AI Video Creation and No Model Required🔥

If you want Tutorial and Code of the Python File to Create such Videos just Hit Follow Button and Comment "Tutorial". I will send you the Pdf Guide in your DM directly ✨

Follow @aiwithshivang for such hacks 🔥🤯

#ChatGPT #claude #GeminiAI #gemini #viral

trillwillisrael 9週
Wow, impressive work! Can't wait to

3.7 萬 823

7月27日

登入以按讚或回應。

9. GPT price drop a lot 10/31

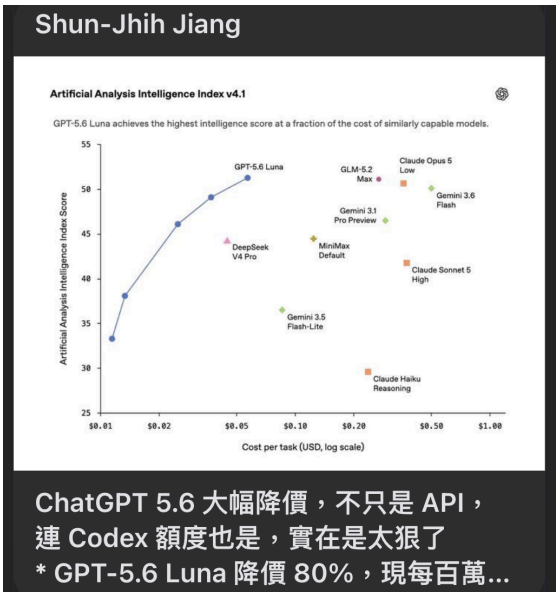

10. Codex: A new application from Chatgpt is now demanding 07/22

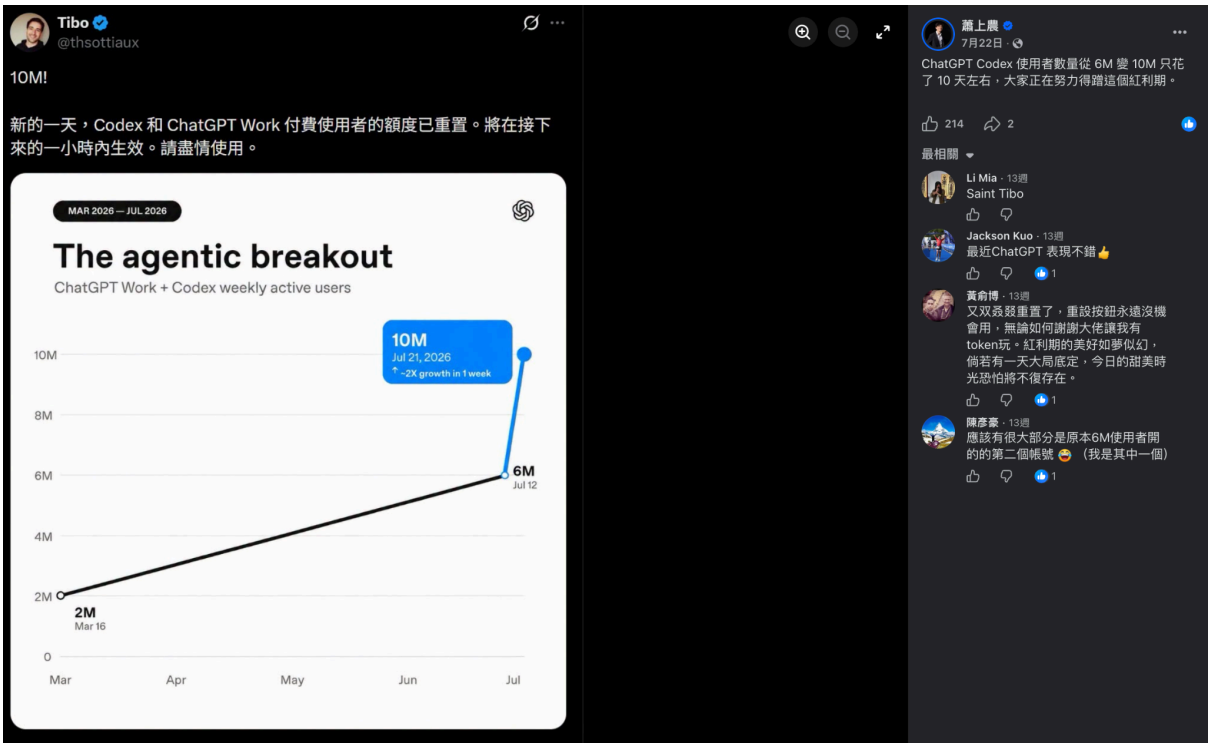

11. Chatgpt vs Geemini 0714 (we can use similarweb data to prove this)

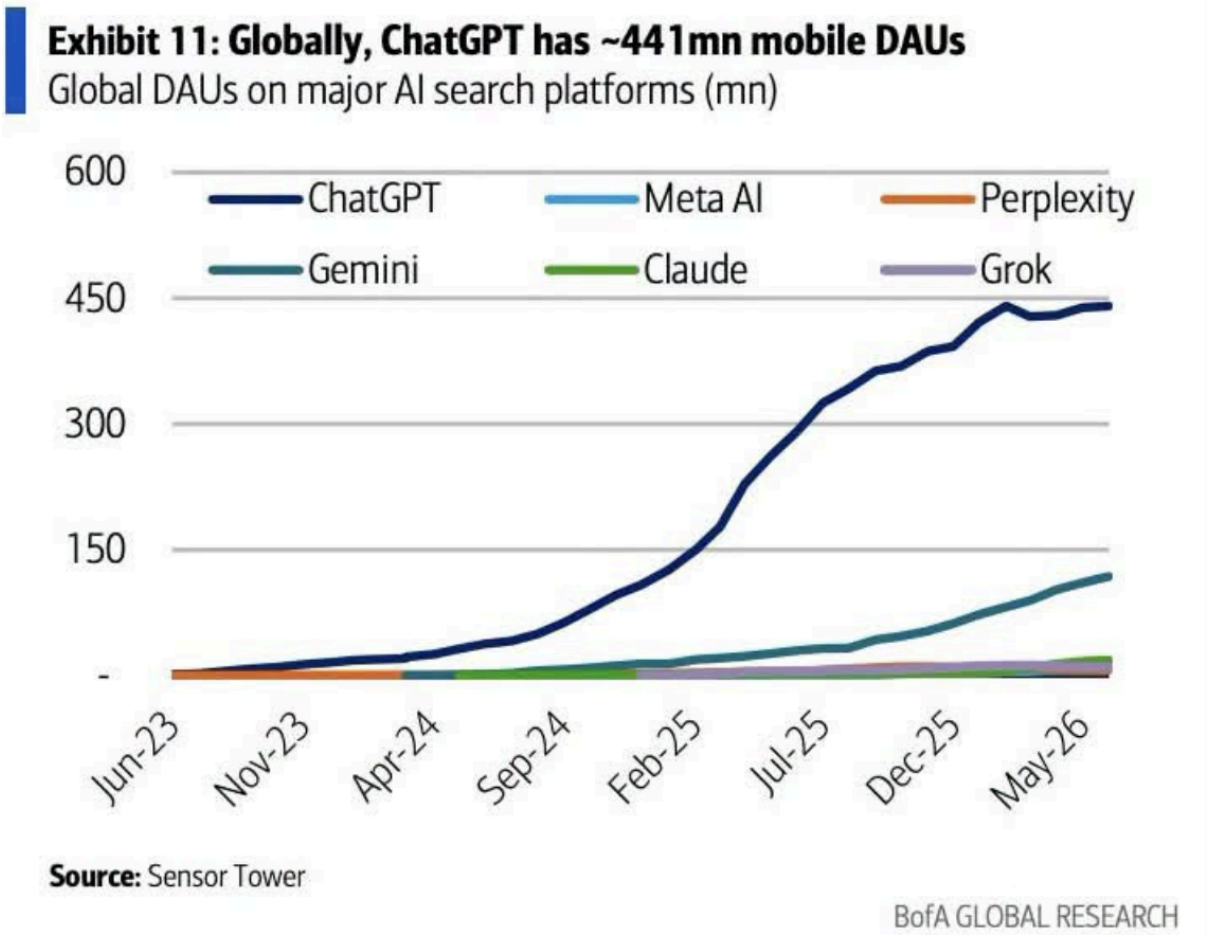

12. Anthropic beats openai on May 0517

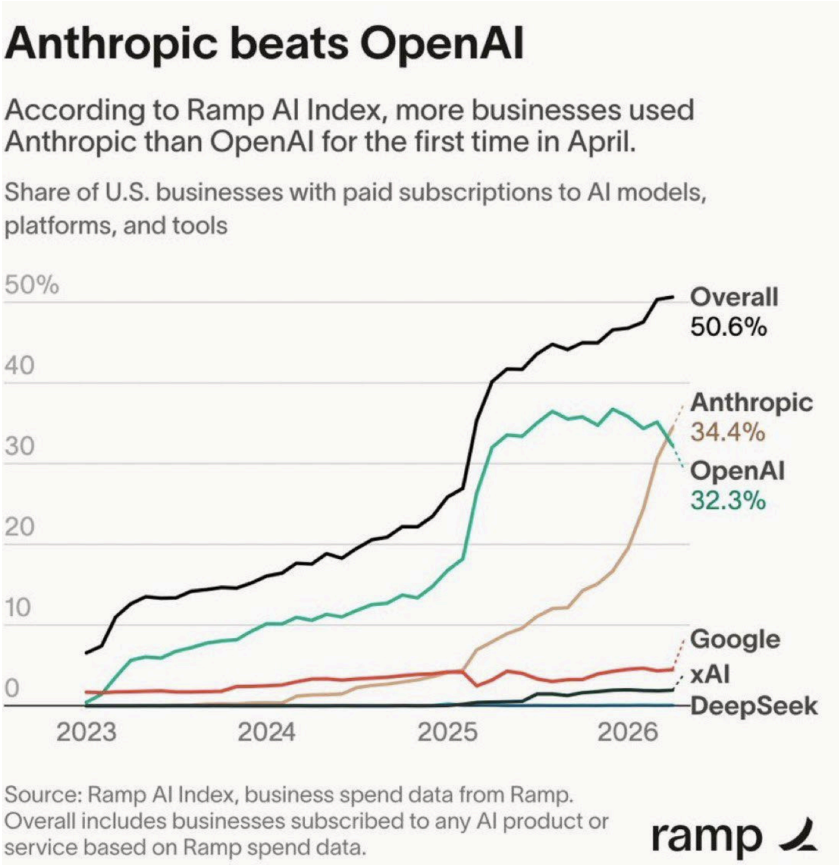

13. 觀點：Gemini & grok 是贏家（same using similarweb to analyze the market)

王伯達觀點
1月9日 ·

AI 行業流量報告：ChatGPT 跌了 22%，受AI影響行業意外平穩？

2025 年最後一季，ChatGPT 流量較前一年下跌了 22%。

這個數字很重要，畢竟 ChatGPT 跟一大串科技公司都掛在一起了。但如果你仔細看 Similarweb 這份報告，會發現更有趣的事情，那些被認為會被 AI 摧毀的傳統行業，其實沒有想像中那麼慘。

線上教育、圖庫網站、傳統搜尋引擎，這些被唱衰的產業，數據表現反而比預期強。相對的，AI 原生工具反而廝殺得更激烈，生圖跟寫作工具的流量都跌了 10%。

不過這份報告有個限制要先說清楚：它追蹤的是網站流量，不包括 API 調用和第三方工具整合。所以 Claude 這種主要透過 API 使用的工具，流量數據不代表真實使用狀況。

但即便如此，這份報告還是能看出一些趨勢。
讓我們來看看這份報告到底說了什麼。

———

1. 通用 AI 工具：Gemini 與 Grok 是大贏家

在通用 AI 工具這個戰場上，表現最好的是 Gemini，年成長 49%，而且全年幾乎都在兩位數成長。Grok 則是從一開始的 9% 年增率快速爬升到年底的 52%。

這兩個模型除了本身能力提升顯著之外，有著廣大的分發基礎是很重要的關鍵。Gemini 深度整合在 Google 生態系裡，Android 手機、Chrome 瀏覽器、Gmail，到處都是它的入口。Grok 則是綁在 X 上，每天數億用戶的流量就是它的基本盤。

相對來說，ChatGPT 全年的成長率最高也只有個位數，到了下半年更是一路南下，從正成長變成負成長。這家公司可能需要更多的紅色警報了。雖然 OpenAI 還有 API 業務跟企業版訂閱，但消費端流量的下滑，代表它在一般用戶心中的地位正在被稀釋。

Claude 全年都有兩位數成長，到了年底則是有些微下滑。這可能跟用戶屬性有關，Claude 的主要用戶是開發者跟專業工作者，年底可能都放長假去了。他們也更傾向透過 API 或第三方工具使用，而不是直接上網站。所以這個流量數據參考性有限。

偏向 Agent 屬性的 Perplexity 與 Manus 則是出現不同走勢。Perplexity 上半年一直都維持很好的表現，但到了第四季開始失速，甚至出現衰退。這家公司可能趁早賣掉比較好。畢竟搜尋這個市場，Google 跟微軟都在虎視眈眈，小公司很難長期存活。

相對的，Manus 推出時就是高峰，但卻一路下滑，到了下半年才逐漸回穩，最後也被 Meta 收購。從這個案例可以看出，Agent 這個賽道還在摸索階段，用戶需求跟產品定位都還沒有清楚的共識。

———

2. 受到 AI 衝擊的傳統行業：意外的強韌

報告追蹤了幾個被認為會被 AI 影響的傳統行業，
但實際狀況似乎沒那麼嚴重。

搜尋引擎：整體下跌 3%

12wk Change	8/1	8/15	8/29	9/12	9/26	10/10	10/24	11/7	11/21	12/5	12/19	1/2
Openai	4%	5%	4%	3%	5%	5%	3%	-2%	1%	-4%	-8%	-22%
Gemini	51%	39%	20%	32%	78%	64%	69%	71%	84%	82%	44%	49%
Deepseek	-27%	-28%	-22%	-17%	-8%	-8%	12%	15%	12%	5%	-2%	-11%
Grok	9%	7%	14%	16%	6%	-13%	5%	13%	28%	43%	49%	52%
Perplexity	26%	14%	17%	20%	37%	66%	39%	39%	32%	17%	7%	-27%
Claude	33%	46%	42%	34%	35%	47%	56%	49%	16%	12%	12%	-14%
Copilot	6%	0%	11%	12%	19%	15%	13%	12%	16%	7%	0%	-19%
Meta	-22%	-21%	-21%	-21%	-15%	102%	82%	73%	79%	109%	98%	-3%
Huggingface	3%	12%	3%	-6%	-4%	-14%	-12%	-18%	-10%	4%	-1%	8%
Manus	25%	2%	-11%	-19%	-14%	-23%	-17%	-16%	-2%	-1%	1%	12%

Source: Similarweb

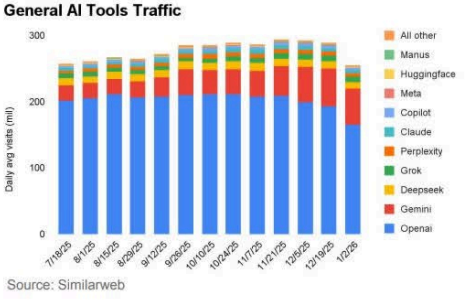

Source: Similarweb

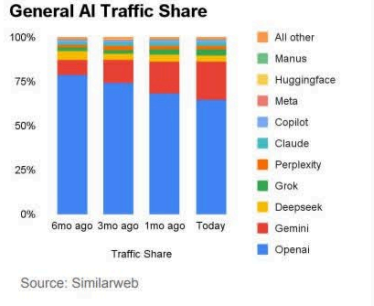

Source: Similarweb

14. 蘋果開始替員工的AI用量踩煞車。部分工程... See more

15.

1. OpenRouter: ppl use chinese open-source model more

2. Chinese open-source model tend to use general GPU (NVIDIA)

HOME › NEWS › THE CLOUD & HYBRID CHANNEL

AI lab Moonshot leases 20,000 Nvidia GPUs from Alibaba Cloud – report

Makes up a significant proportion of Moonshot's overall compute capacity for Kimi models

August 04, 2026 By: Georgia Butler Have your say

Add as a preferred source on Google

Chinese AI lab Moonshot reportedly has a compute capacity agreement with Alibaba Cloud to the tune of 20,000 Nvidia GPUs.

As reported by Bloomberg and citing people familiar with both companies' operations, the Nvidia GPUs make up a large proportion of Moonshot's total compute capacity used for the training and running of the Kimi models.

Moonshot and Nvidia declined to comment to Bloomberg.

3. OPEN OR CLOSED? The gap is still shrinking 07/23

Generative AI 技術交流中心
胡嘉璽 · 7月23日 ·

是認真考慮地端模型實際應用的時候了，Kimi-k3/Qwen 3.8 的啟示

小米天才少女羅福莉（也是目前 MiMo 模型的負責人）在今年四月二十日接受訪談時提到，目前要進入 LLM 賽道的基本門檻，是 1TB 參數級別的模型。為什麼是這個數字？因為這就是當時 Opus 4.6 的水準。不管你想玩的是開放權重（Open-weights）還是商用模型，想進場，這就是基本盤。

其實從 GPT-3.5 閉源之後，大家就一直在猜這些 Frontier 模型到底有多大。各家基本的招數大同小異，但這些微調（或調校）或模型內部的修改，始終離不開 LLM 基礎的 Scaling Laws。隨著模型越來越強，大家猜的數字也越來越高，而羅福莉算是第一次給出了精確的數字。

Anthropic CEO Dario Amodei 也說過，開放權重模型和頂級商用模型之間的技術差距大約是 6 到 18 個月。往前推算的話， 6 個月前（也就是今年一月）大約就是 Opus 4.6 的水準。換句話說，現在頂級的開放權重模型，對多數應用場景來說已經「非常夠用」了。

現在發表的 Qwen 3.8 Max 參數量也來到了 2.4T。如果真的如其宣稱的效能，Qwen 3.8 Max 絕對是能和 Fable 5 拚一拚的，更別說還沒正式開放的 Kimi-k3，在 Arena.ai 的 WebDev 測試中已經直接幹掉 Fable 5 了！

這代表什麼？

以 2.4T 量化後的模型來說，你可以用大約 15 台 GB300 架起這個接近 Fable 5 實力的地端模型，專供固定團隊使用。大家可能會吐槽：「15 台 GB300 就要 150 萬美金了，這筆錢夠我訂閱幾百輩子的 Claude Code Max 20x！」

但重點不僅僅是錢，重點是：我可以在自己的私有雲，甚至是區域網內，提供 Fable 5 等級的服務給內部使用！企業的安全邊界，終於能從遙遠的公有雲，拉回公司內部可控的私有雲內。資料合法合規、智財外流疑慮、主管機關裁罰，都不再是問題！

用錢能解決的事都不算大事。大約 200 萬美金左右的軟硬體投資，就能換得內部擁有 Fable 5 等級的 Agent 執行品質；如果是上市櫃公司的企業主，他們腦中算的是另一本帳。畢竟企業若遭主管機關裁罰，動輒上千萬，打起官司更是億來億去。這個巨大的誘因，相信正是這幾個新模型即將帶來的產業新秩序。當然，中國模型在台灣有特殊的法規限制，但對其他的全球企業來說，能跑在地端的 Fable 5 級別模型？簡直不可思議！

今天剛好在談這個話題，如果你想做概念驗證（POC），120B 的模型已經可以完成相當複雜的工作了。靠一台 DGX Spark 或 MacBook 128GB 就可以先上手試試。從前被我們視為玩具的開放權重模型，在 Qwen 3.8 Max 發表後，真的具備了與 Frontier 模型正面對決的實力，再加上一直在前段班的 GLM-5.2，現在矽谷那些 AI 巨頭們，心裡恐怕不知急成什麼樣子了！

- 我覺得這邊真的很好講 可以很好連結到TSMC：The more advanced and need for open-source models, the more need for NVIDIA gpu
- 可以從Kimi出發：講目前的開源生態（gap bw open and close - AA data）-> Kimi造成的轟動(throughput and ttft surge - AA data & web app usage - Similarweb data) -> general gpu is still the fundamental needs (leasing price for CPU/GPU) -> Impact (gpu demand ? US frontier models strategy e.g. lower their price - AA data?)
- 可以連結到why Jensen ask Trump not to ban Chinese open source models?

4. Kimi is hot!! 07/20

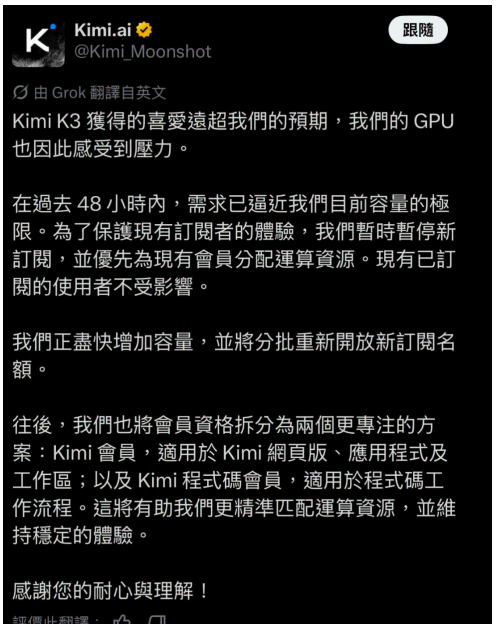

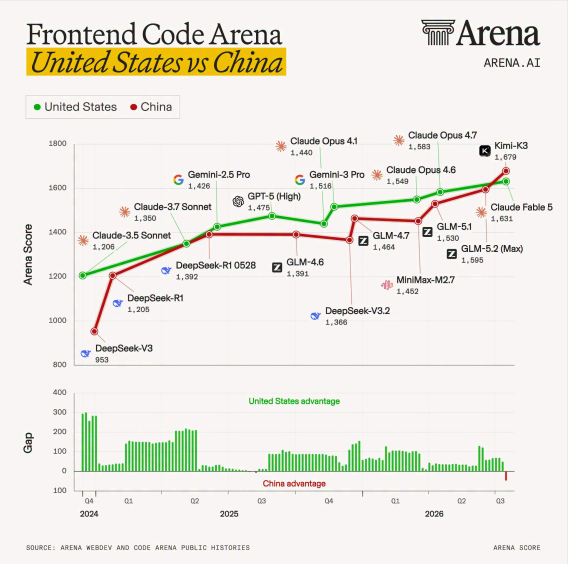

5, Restrictions on Open source models 07/22

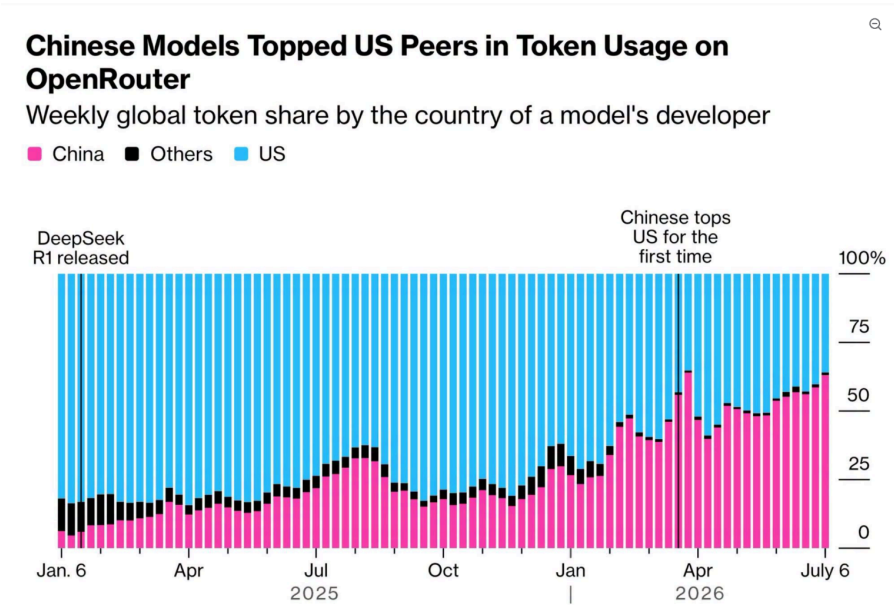

6. CP值for each model (CS 看的那張象限圖）

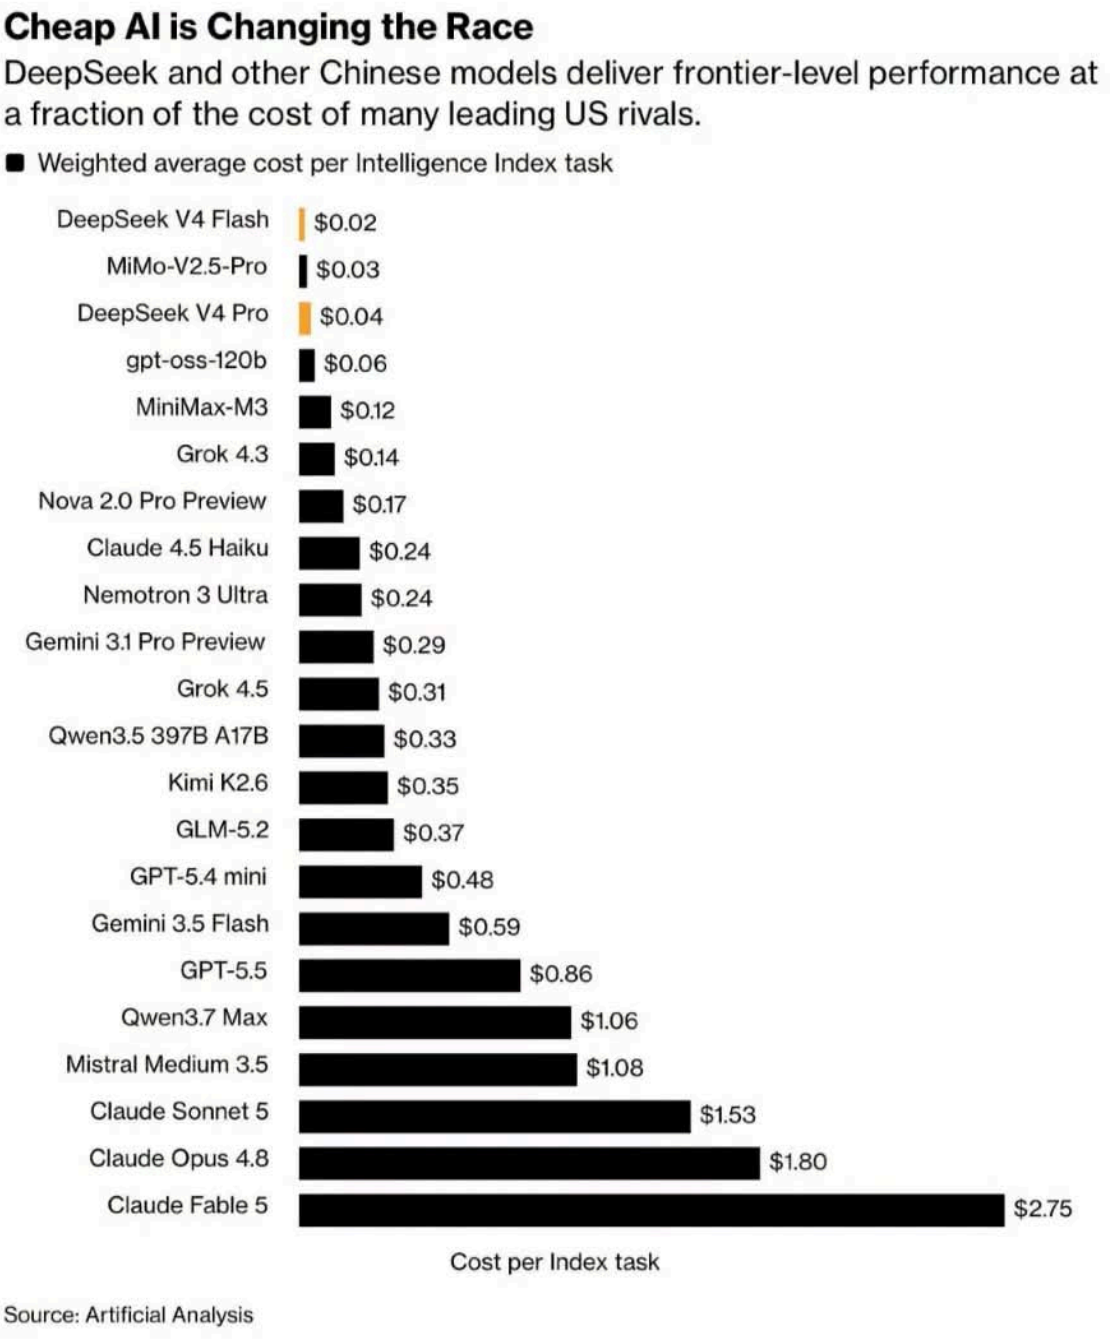

7. Open source vs closed source 0718

美股探路客
7月18日 ·

OpenRouter統計『美國企業使用中國AI模型的token數量』比例已經超越美國的模型

根據目前無程式碼AI Agent領先公司Lindy AI CEO的說法，上個月從Anthropic轉到Deepseek後，已經節省了90%的推論成本

雖然美國可能祭出鐵拳，禁止美國企業使用中國模型，但他預測Alphabet、Meta約3～6個月，就能釋出類似的開放權重模型，因此若失去中國模型使用權，對成本有影響但不是世界末日

所以領先模型公司，特別是Anthropic、OpenAI若無法降低推論成本，成長可能受限、壓力會越來越大

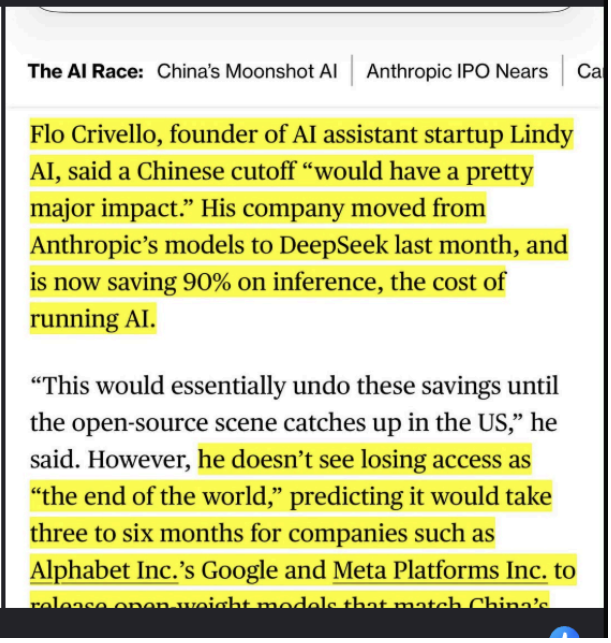

8. Chinese models have overtaken US conterparts this year 07/14

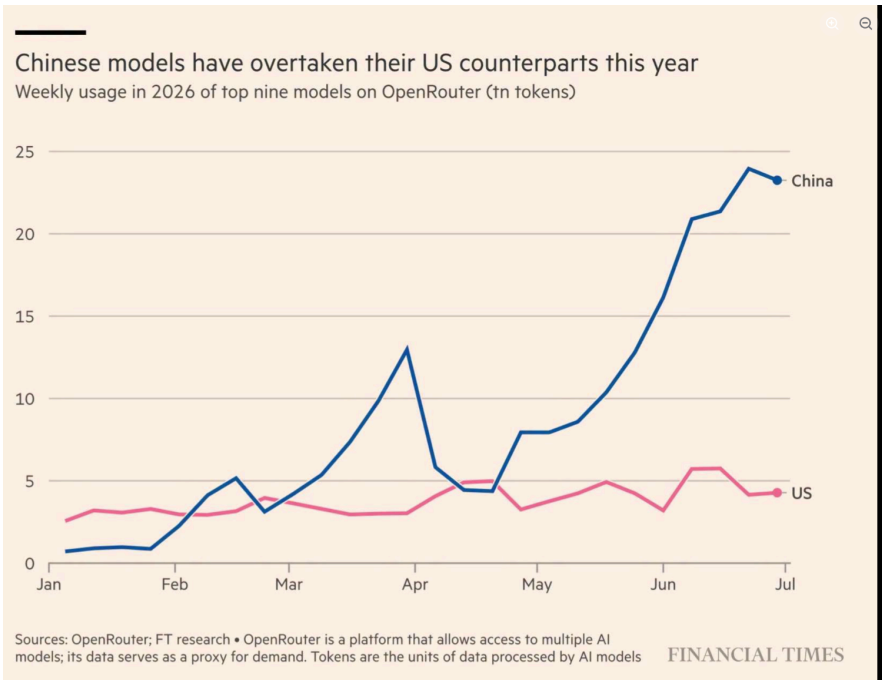

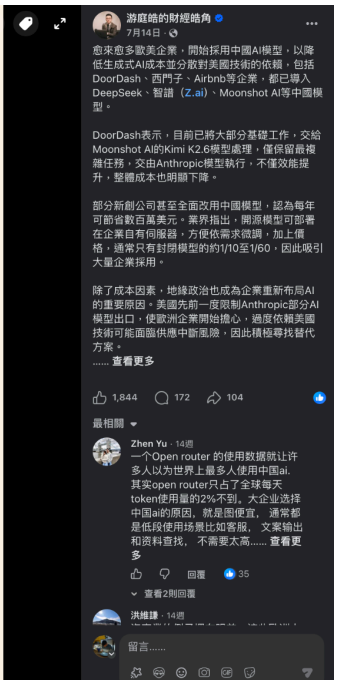

9. Deepseek news model release 0426 - 看open source closed source 用量分析

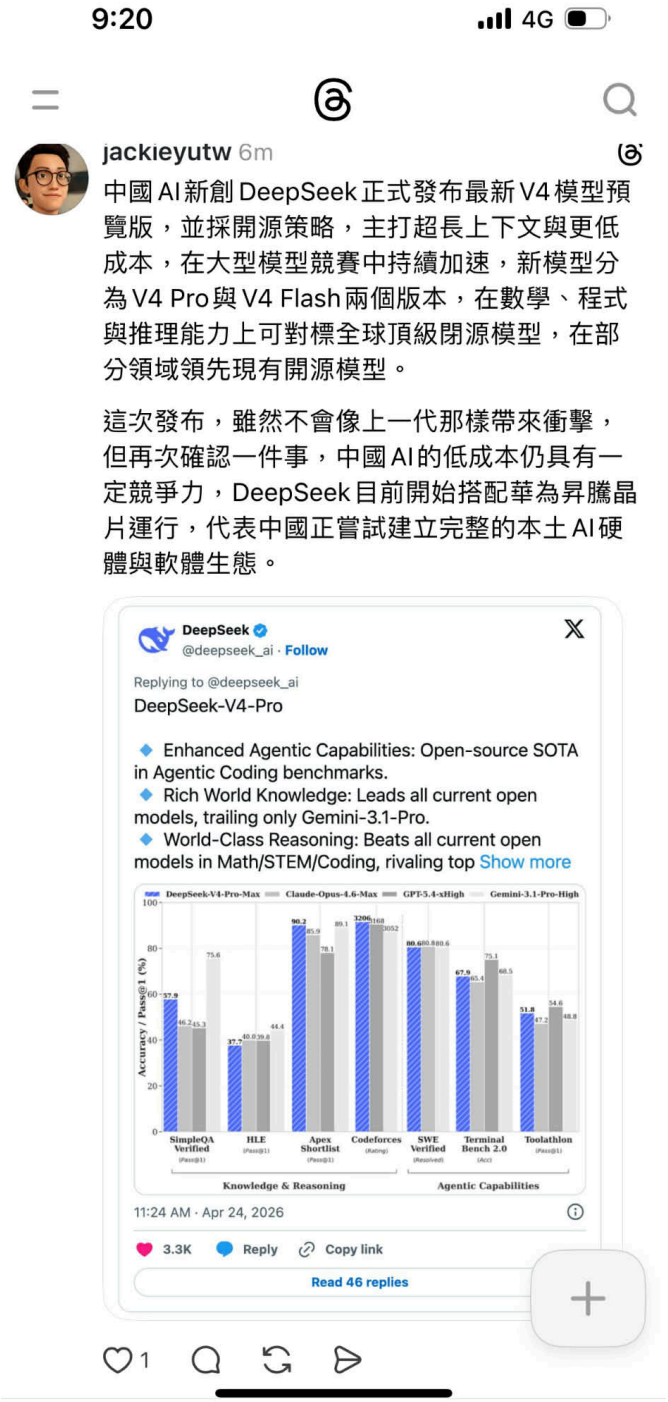

1. OpenAI makes their own chip 08/26

哈利說
8月26日 ·

哇靠，OpenAI 自己做的晶片還真有點厲害！

昨晚他們終於公佈跑分，結果大勝 NVIDIA Blackwell，而且整個測試竟然大致是公平的。

使用的 benchmark 是 SemiAnalysis 的 InferenceX，算是業界目前針對 LLM 推論的最好測試了。

這次結果能證明的是：單一機櫃內，Jalapeño 在 LLM 推論的延遲、吞吐量、每單位能源的表現上比 GB200/GB300 更好。

這點本身已經很驚人了，但我們知道 NVIDIA 真正強的是整個 AI factory 規模的 extreme co-design。

Factory 規模的每單位能源表現還有待觀察。另外我們也不知道 OpenAI 跑測試時用的 NVIDIA 軟體層是否真的是最好的。

但不得不說，OpenAI 這次真的不是來玩的。第一張晶片，這麼短的研發時間，竟然可以有這種表現……

只能說 AI 也是完全改變了晶片開發本身。(OpenAI 說有使用 AI 協助開發)

下面幫大家整理詳細的測試環境跟結果。

測試環境：

使用 SemiAnalysis 的 InferenceX benchmark，測試真實 LLM inference serving，而不是單純比較晶片理論算力。測試三個大型模型：

- GPT-OSS 120B：Jalapeño vs. NVIDIA GB200
- DeepSeek R1 670B、Kimi K2.5 1T：Jalapeño vs. NVIDIA GB300

Workload 約為 8K input / 1K output。

1. 最高吞吐量 / 功耗：比 GB200 / GB300 高 1.5～1.9×

當兩邊都盡量把系統塞滿、追求最高產能時，Jalapeño 每 1 kW 可以處理 1.5～1.9 倍更多 tokens：GPT-OSS 對 GB200 為 1.9×；DeepSeek、Kimi 對 GB300 分別為 1.7×、1.5×。

意義： 同樣的資料中心電力，Jalapeño 可以服務更多 AI inference。

但要注意： 這裡是用晶片的「額定功耗（TDP）」換算，而不是直接測量整個伺服器或機櫃的實際耗電。

2. 完成一次 Request：比 GB200 / GB300 快 1.7～3.6×

Jalapeño 完成一次完整 inference，GPT-OSS 比 GB200 快 1.7×；DeepSeek、Kimi 比 GB300 分別快 3.6×、3.4×。

意義： 使用者或 AI Agent 丟出一個任務後，可以更快完成一次 inference。

但要注意： 這是特定 8K input / 1K output workload 的結果，換成更短或更長的 context，差距可能不同。

3. 單一使用者 Token 速度：比 GB200 / GB300 快 2.7～4.1×

2. ASIC roadmap 08/20

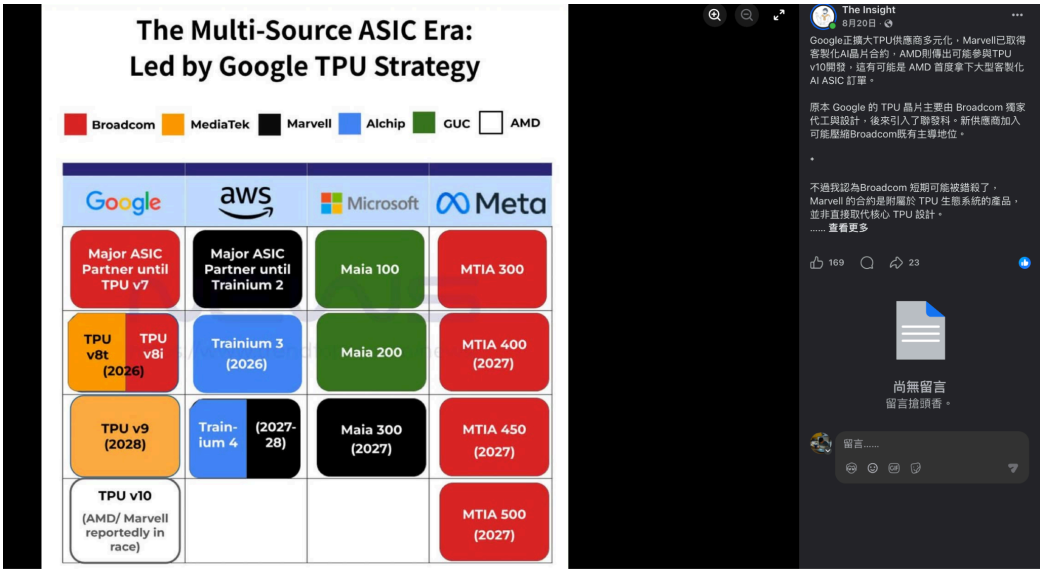

3. Openal chip - Jalapeno

游庭皓的財經皓角 · Follow

5d ·

OpenAI正式發表，與博通共同開發的首款人工智慧專用晶片 Jalapeno，目前已完成首批樣品並進入測試階段。

這款晶片在執行 AI 推論任務時，成本可望較傳統圖形處理器，降低約 50%，同時在能源效率方面，也優於現有主流產品。

未來將陸續導入微軟等合作夥伴的大型資料中心，最快今年下半年開始部署，看得出來，OpenAI正積極降低對輝達晶片的依賴，建立自己的AI硬體供應鏈。

OpenAI今年稍早，完成高達1,220億美元募資，並持續投入資料中心、晶片與基礎設施建設，除了與超微、塞布拉斯等業者合作外，如今更進一步推出自研晶片，希望掌握從模型、軟體到硬體的完整技術架構。

雙方已規劃下一代晶片開發藍圖，預計2028年推出升級版本，之後將以每年更新一次的速度推進，未來頂尖AI公司，自行設計專屬晶片，已成為產業發展的新趨勢。

OpenAI
@OpenAI

顯示翻譯

We've designed and built our first AI chip: Jalapeño.

Designed from the ground up by OpenAI and brought to production with

1. AI bot surpass human now 08/04

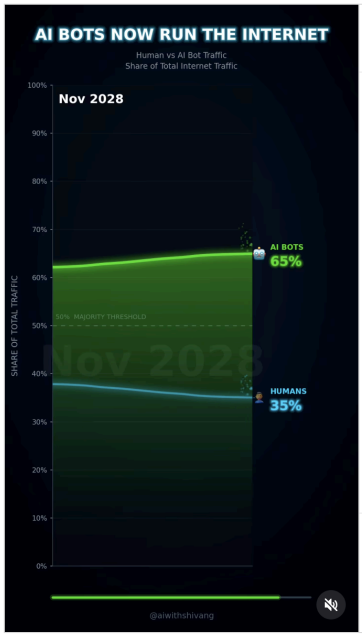

aiwithshivang • 追蹤
1HXSX, wnorg17 • REVENGE (Super Slowed)

aiwithshivang 11週
AI bots taking over Humans on the Internet 🚀

Data is based on the research done by different research and of course Claude.

Share this🔥

aiwithshivang 11週
Tutorial link to create such videos free Pdf download from below link or link in bio 🚀👇:
https://aiwithshivang.in/resources/build-viral-ai-race-videos-using-python-step-by-step-guide

讚 回覆

39 1

8月4日

登入以按讚或回應。

2. Only 1% ppl spending money on AI

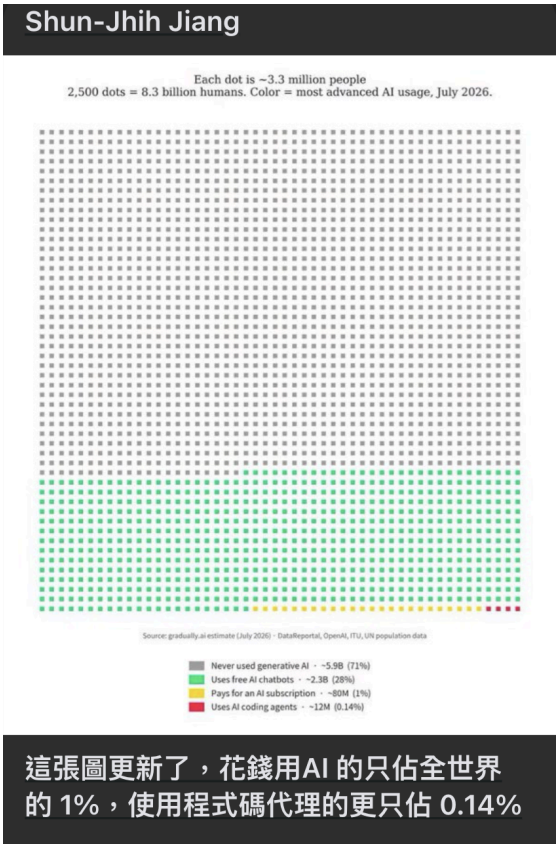

3. Are we in the bubble ? 07/04

eth_119 2026-7-4

有越燒越上層的 跡象喔

1.終端：承認AI模型目前不賺錢
（meta已經承認了）

2.甲骨文出租算力的公司、也罕見承認未來會虧損
（好巧不巧meta又參戰了）

3.接下來再往上走、就是nvda銷量暴雷

4.晶片供應商 台積電、英特爾。就要小心了。

2.362 343 70 1.495

4. 從成本看AI**Bubble 0703 ~10/26**

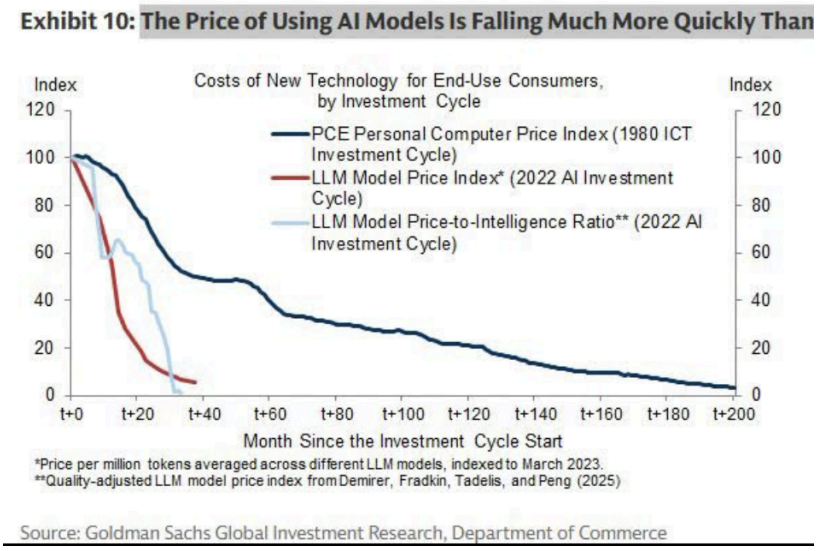

Epoch AI 在《The Plunging Price of Thought》報告中，將 AI 模型產生答案的能力比喻為「人工思考」（artificial thought），並比較多項科技的成本變化。研究估計，相同表現水準的 AI 推論成本自 2023 年起每季下跌約 47%。若把這個跌速延伸至約五年，累計降幅可達數十萬倍；不過報告主要分析的是約三年數據，較長時期的跌幅仍屬推算。

以平均每年跌價速度比較，AI 推論成本下降速度約為 DNA 排序的 4 倍、傳統運算技術的 6 倍、鋰電池的 18 倍，以及早期電力發展的 54 倍。Epoch AI 同時提醒，AI 服務持續演變，與電力或電池等產品並不完全相同，跨技術比較只能做為參考。

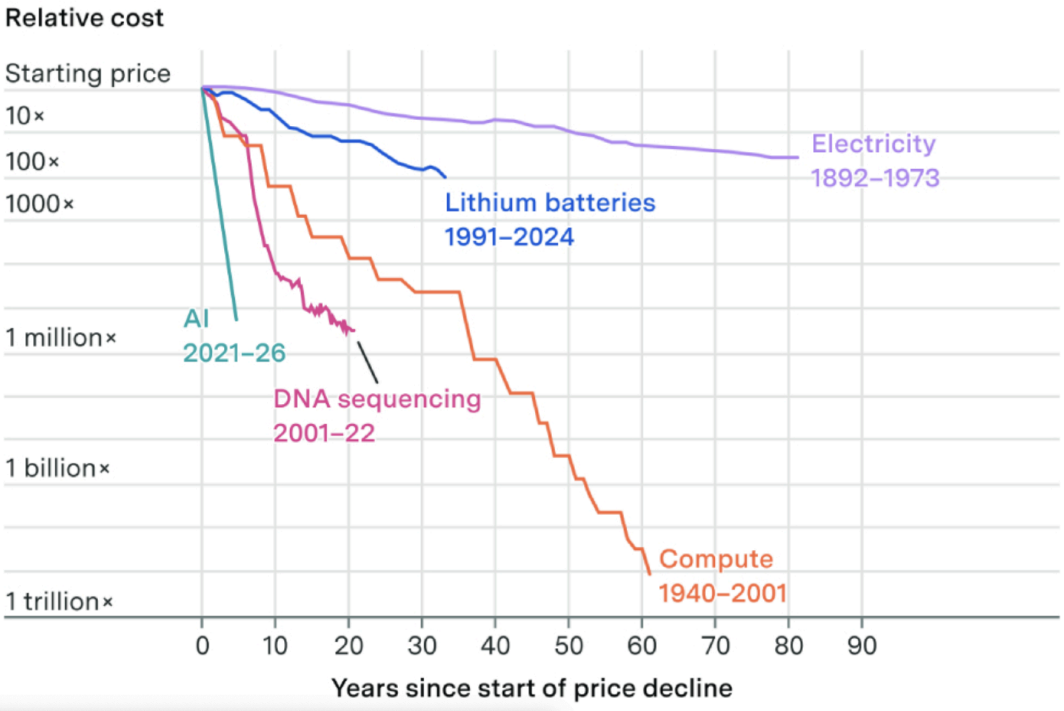

科技持續進步，算力成本開始下滑，但AI基建投資還沒結束。這幾個月，AI產業正出現一個看似矛盾的現象，一方面，開源模型能力快速追趕，推理成本與Token成本持續下降。

例如中國智譜最新推出的GLM-5.2模型，在程式開發等測試項目，已接近頂級閉源模型水準；日本新創Sakana AI推出的Fugu系統，則透過協調多個模型合作運算，在SWE-Bench Pro測試獲得73.7分，甚至超越部分頂級商業模型。

與此同時，AI伺服器租賃價格持續下滑，市場過去認為算力永遠短缺的敘事，正開始受到挑戰。

不過即使成本下降，企業目前仍沒有減少支出的跡象，全球AI Token使用量已逐漸穩定，半導體股買盤仍十分強烈，市場依舊相信AI基礎建設投資週期尚未結束。

關鍵問題在於，當模型越來越便宜、能力差距越來越小之後，未來究竟會創造出更多需求，還是壓縮整個產業的獲利能力。

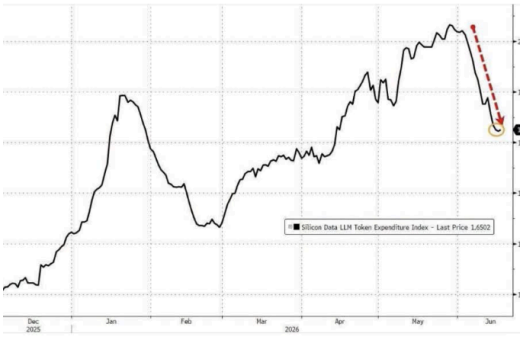

1.3K 18 33

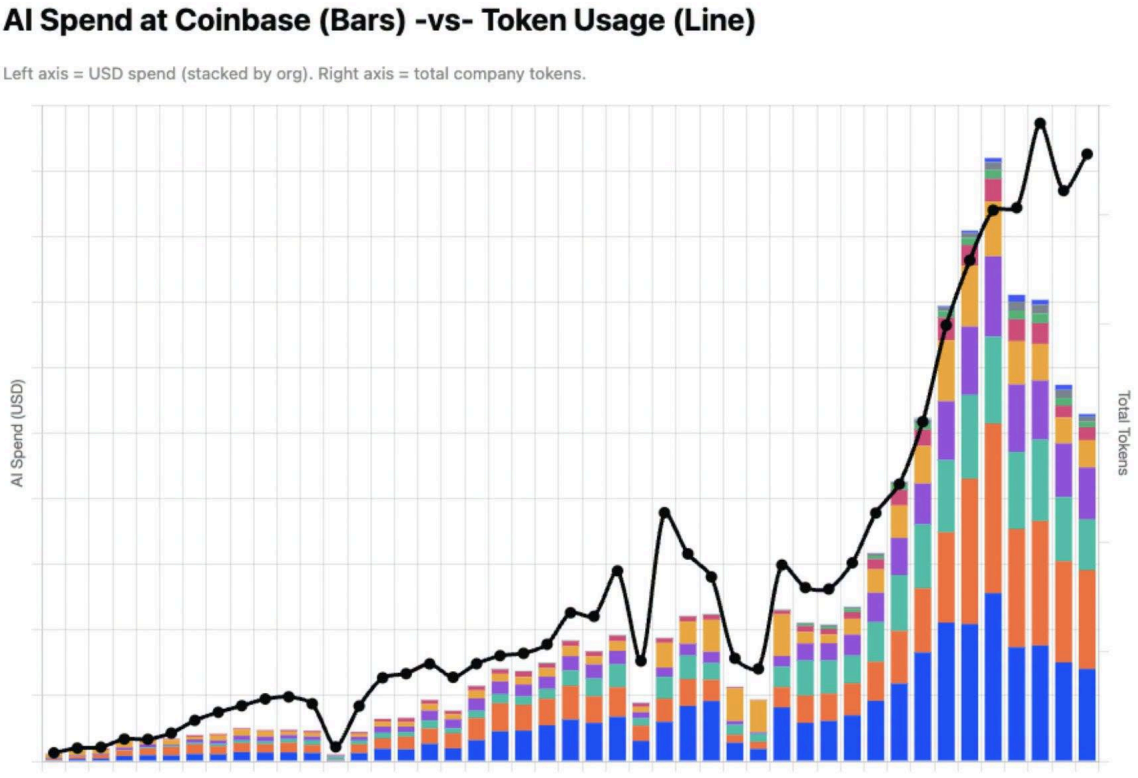

Blackwell 的 35 倍世代躍進

與此同時，NVIDIA 自家 Blackwell 架構也展現了驚人的世代躍進。根據官方基準測試，從 Hopper 世代（H200）到 Blackwell，每百萬 Token 成本從 **$4.20 美元**驟降至 **$0.12 美元**，降幅高達 **35 倍**。

更具說服力的是實際吞吐量對比：在運行 DeepSeek-R1 模型時，Blackwell GB300 NVL72 配置每顆 GPU 可生成 **6,000 個 Token**，而 H200 僅為 90 個 Token。雖然 Blackwell 每 GPU 小時成本約為 $2.65 美元（高於 H200 的 $1.41 美元），但實際 Token 產出相差近 67 倍。

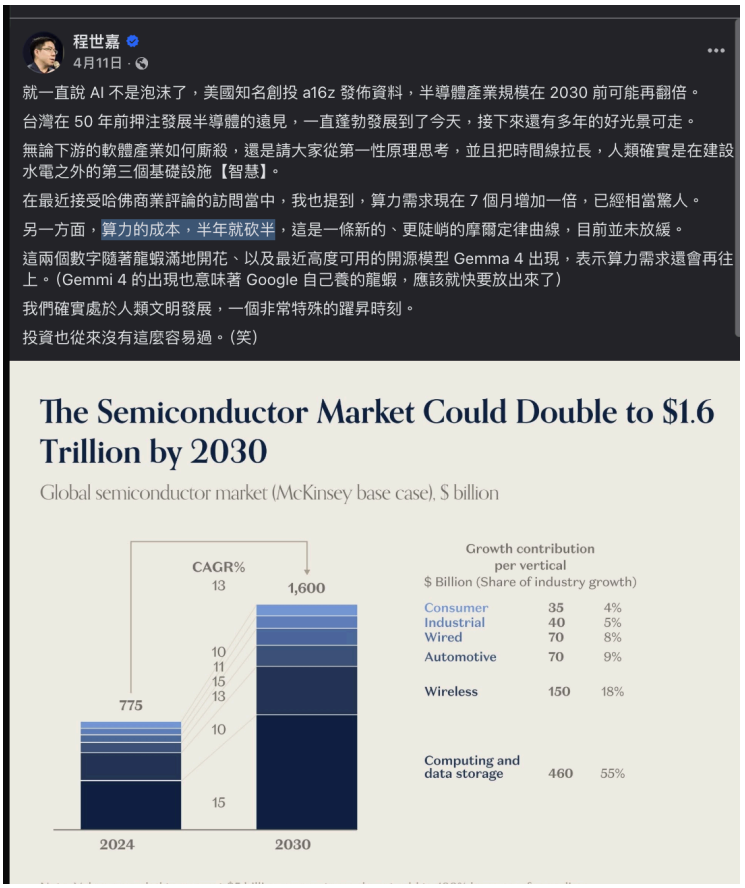

- 這個主題我覺得也可以講一下：用成本的角度 (token price - AA) / B2B (Census) / B2C (Similarweb) / Finance (debt to equity ratio, Capex, CDS - BBG) 分析AIbubble

5. AI bubble 的一些觀點

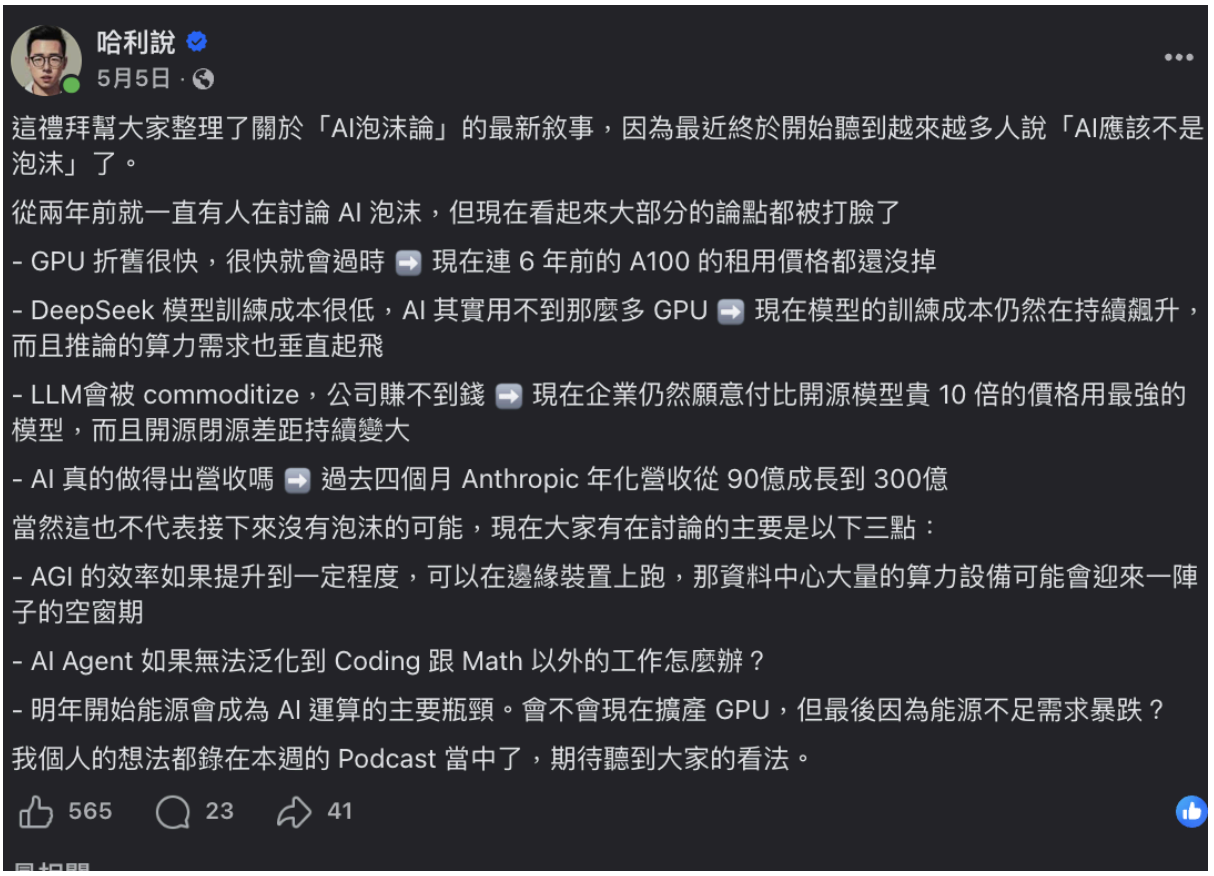

哈利說
5月5日 ·

這禮拜幫大家整理了關於「AI泡沫論」的最新敘事，因為最近終於開始聽到越來越多人說「AI應該不是泡沫」了。

從兩年前就一直有人在討論 AI 泡沫，但現在看起來大部分的論點都被打臉了

- GPU 折舊很快，很快就會過時 ➡️ 現在連 6 年前的 A100 的租用價格都還沒掉

- DeepSeek 模型訓練成本很低，AI 其實用不到那麼多 GPU ➡️ 現在模型的訓練成本仍然在持續飆升，而且推論的算力需求也垂直起飛

- LLM會被 commoditize，公司賺不到錢 ➡️ 現在企業仍然願意付比開源模型貴 10 倍的價格用最強的模型，而且開源閉源差距持續變大

- AI 真的做得出營收嗎 ➡️ 過去四個月 Anthropic 年化營收從 90億成長到 300億

當然這也不代表接下來沒有泡沫的可能，現在大家有在討論的主要是以下三點：

- AGI 的效率如果提升到一定程度，可以在邊緣裝置上跑，那資料中心大量的算力設備可能會迎來一陣子的空窗期

- AI Agent 如果無法泛化到 Coding 跟 Math 以外的工作怎麼辦？

- 明年開始能源會成為 AI 運算的主要瓶頸。會不會現在擴產 GPU，但最後因為能源不足需求暴跌？

我個人的想法都錄在本週的 Podcast 當中了，期待聽到大家的看法。

565 23 41

6. 1106

發了 6 到 9 倍，但蘋果投進去的錢，反而比這波 AI 浪潮還沒開始前還要少。

這種差異也反映在資本支出佔銷售額的比例上，當這些大型雲端業者的比例增加了 2 到 3 倍時，蘋果的佔比反而縮水了大約三分之一。

換個角度來看，從 2023 年第 1 季開始，Alphabet、微軟、亞馬遜跟 Meta 這幾家大廠的資本支出都已經翻了 5 到 8 倍，反觀蘋果目前的投入金額，竟然比這波 AI 熱潮爆發前還少了 20%。

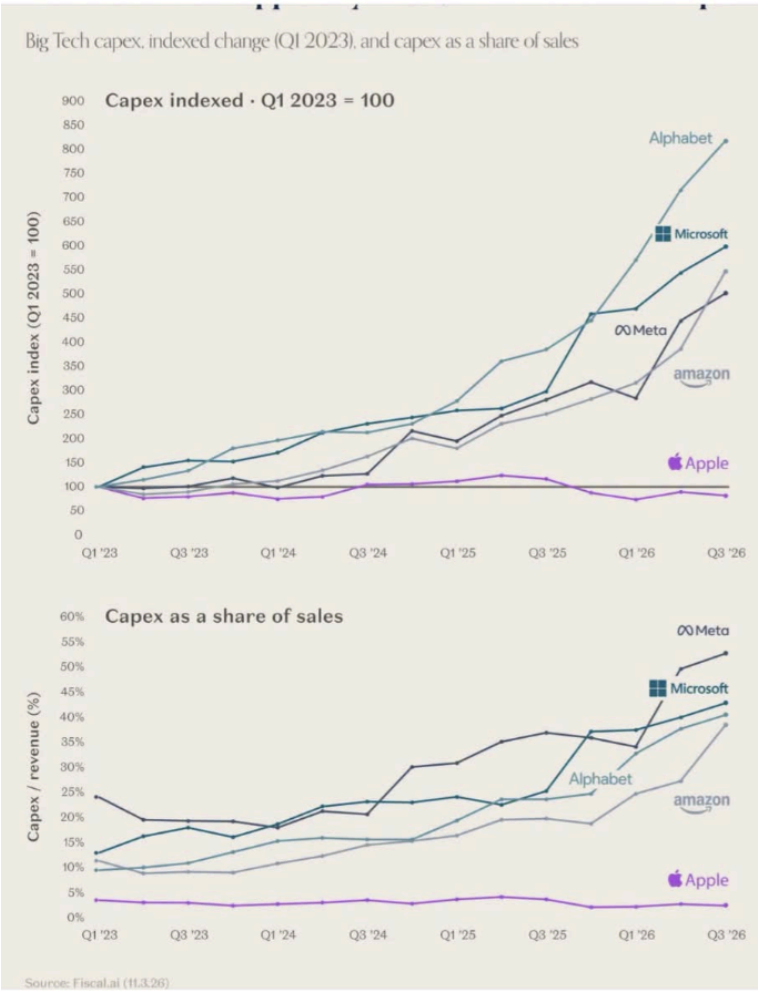

1. MSFT: model and services performance 07/30

msft

目前盤後看起來是少數沒因為開好成績而被市場重懲的公司，相較於其他大玩家 (alphabet $180-190B 上修到 $195-205B，meta $125-145B)，資本支出較為持平沒上修。但對 AI 和供需都還是非常樂觀
---

copilot (source satya x)
- 用戶對話次數較去年同期成長一倍
- 每週參與度與 Outlook 和 Teams 持平
- 超過 5 萬個席次的客戶數量年增 7 倍
- 向資訊工作者部署 Copilot 的客戶數量較上季成長 75%

frontier performance curve
https://microsoft.ai/news/optimizing-the-frontier-performance-curve/
- MAI-Cyber-1-Flash 在 CyberGym benchmark 領先 Mythos 12 個百分點，成本只有一半
- MAI-Code-1-Flash 的程式碼接受率提高 10%，token 用量降低 10%
- PowerPoint 影像：GPU 成本最多降低 84%。
- 客服語音：Dynamics 365 Contact Center 的 GPU 成本最多降低 89%
- 醫療轉錄：MAI-Transcribe-1.5 的轉錄及語言辨識錯誤率相對下降 50%。
- 自研晶片：MAI 模型跑在 Maia 200 上，每瓦效能改善 40%

2. Gemini launch delay 0717

3.
4.

1. Hyperscaler April financial status 0430

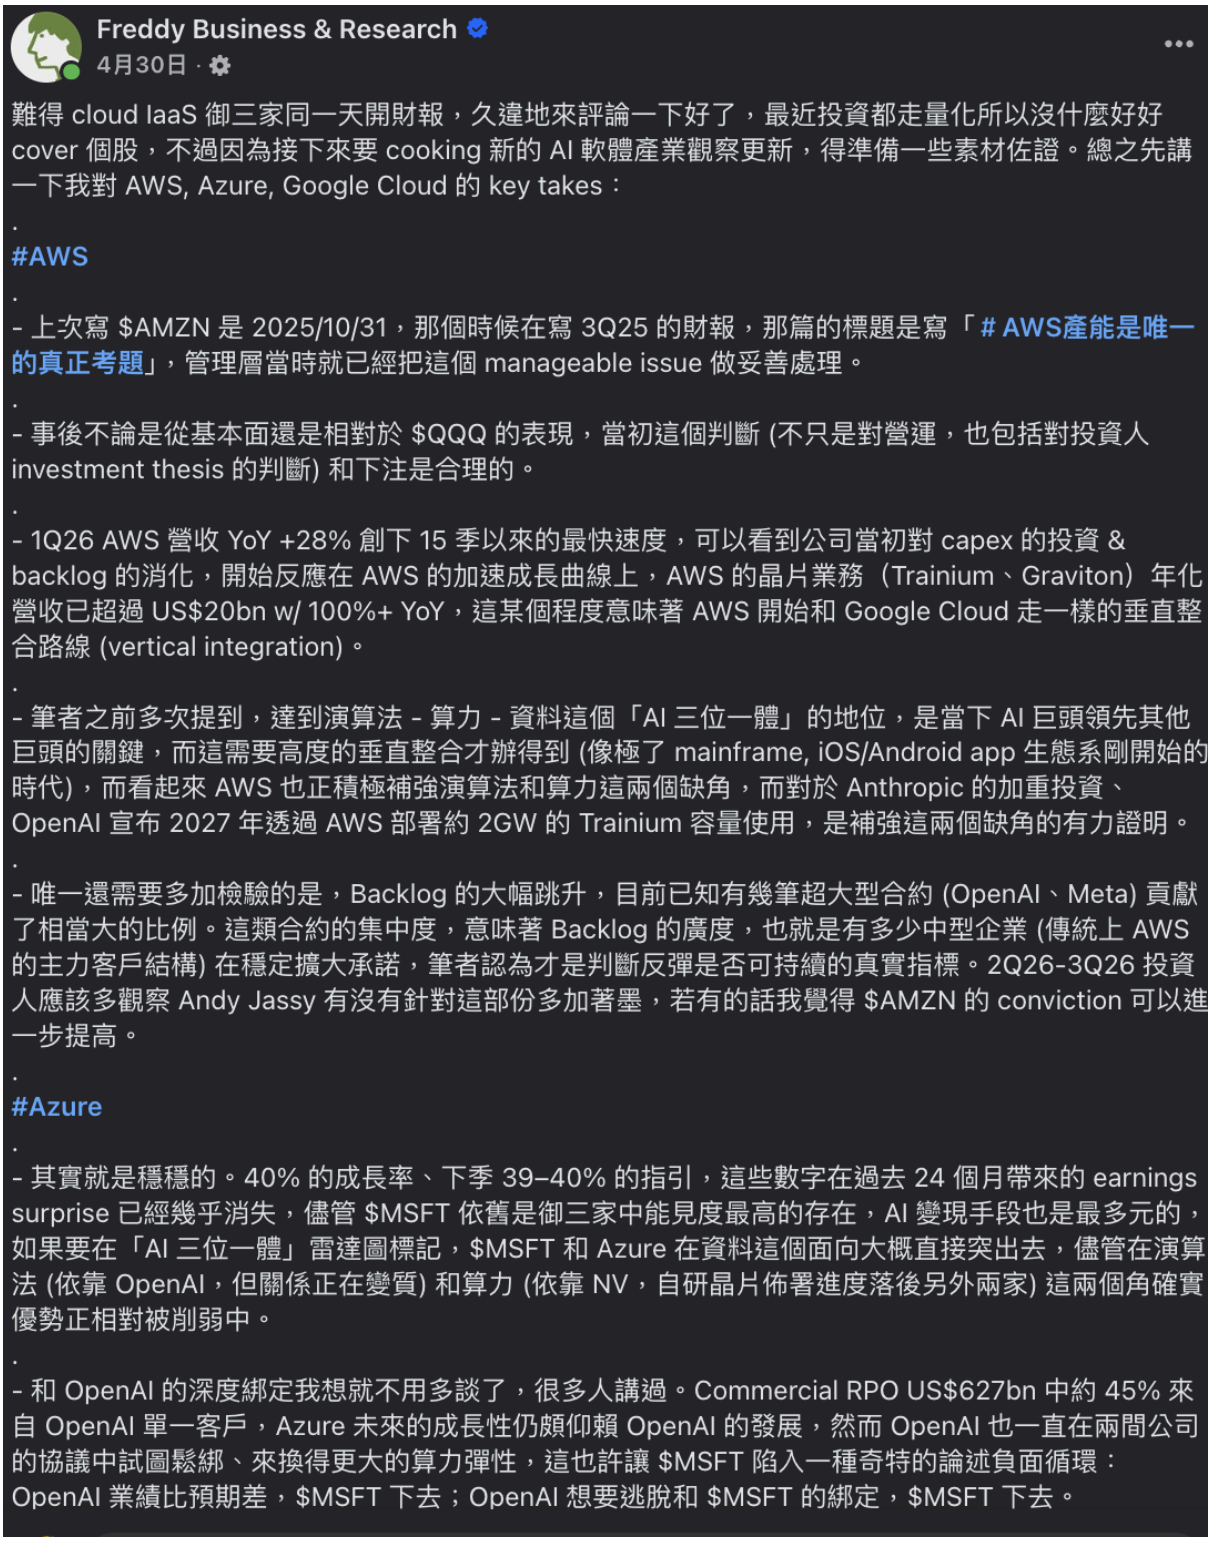

Freddy Business & Research
4月30日 ·

難得 cloud IaaS 御三家同一天開財報，久違地來評論一下好了，最近投資都走量化所以沒什麼好好 cover 個股，不過因為接下來要 cooking 新的 AI 軟體產業觀察更新，得準備一些素材佐證。總之先講一下我對 AWS, Azure, Google Cloud 的 key takes：

.

#AWS

.

- 上次寫 $AMZN 是 2025/10/31，那個時候在寫 3Q25 的財報，那篇的標題是寫「# AWS產能是唯一的真正考題」，管理層當時就已經把這個 manageable issue 做妥善處理。

.

- 事後不論是從基本面還是相對於 $QQQ 的表現，當初這個判斷 (不只是對營運，也包括對投資人 investment thesis 的判斷) 和下注是合理的。

.

- 1Q26 AWS 營收 YoY +28% 創下 15 季以來的最快速度，可以看到公司當初對 capex 的投資 & backlog 的消化，開始反應在 AWS 的加速成長曲線上，AWS 的晶片業務（Trainium、Graviton）年化營收已超過 US$20bn w/ 100%+ YoY，這某個程度意味著 AWS 開始和 Google Cloud 走一樣的垂直整合路線 (vertical integration)。

.

- 筆者之前多次提到，達到演算法 - 算力 - 資料這個「AI 三位一體」的地位，是當下 AI 巨頭領先其他巨頭的關鍵，而這需要高度的垂直整合才辦得到 (像極了 mainframe, iOS/Android app 生態系剛開始的時代)，而看起來 AWS 也正積極補強演算法和算力這兩個缺角，而對於 Anthropic 的加重投資、OpenAI 宣布 2027 年透過 AWS 部署約 2GW 的 Trainium 容量使用，是補強這兩個缺角的有力證明。

.

- 唯一還需要多加檢驗的是，Backlog 的大幅跳升，目前已知有幾筆超大型合約 (OpenAI、Meta) 貢獻了相當大的比例。這類合約的集中度，意味著 Backlog 的廣度，也就是有多少中型企業 (傳統上 AWS 的主力客戶結構) 在穩定擴大承諾，筆者認為才是判斷反彈是否可持續的真實指標。2Q26-3Q26 投資人應該多觀察 Andy Jassy 有沒有針對這部份多加著墨，若有的話我覺得 $AMZN 的 conviction 可以進一步提高。

.

#Azure

.

- 其實就是穩穩的。40% 的成長率、下季 39–40% 的指引，這些數字在過去 24 個月帶來的 earnings surprise 已經幾乎消失，儘管 $MSFT 依舊是御三家中能見度最高的存在，AI 變現手段也是最多元的，如果要在「AI 三位一體」雷達圖標記，$MSFT 和 Azure 在資料這個面向大概直接突出去，儘管在演算法 (依靠 OpenAI，但關係正在變質) 和算力 (依靠 NV，自研晶片佈署進度落後另外兩家) 這兩個角確實優勢正相對被削弱中。

.

- 和 OpenAI 的深度綁定我想就不用多談了，很多人講過。Commercial RPO US$627bn 中約 45% 來自 OpenAI 單一客戶，Azure 未來的成長性仍頗仰賴 OpenAI 的發展，然而 OpenAI 也一直在兩間公司的協議中試圖鬆綁、來換得更大的算力彈性，這也許讓 $MSFT 陷入一種奇特的論述負面循環：OpenAI 業績比預期差，$MSFT 下去；OpenAI 想要逃脫和 $MSFT 的綁定，$MSFT 下去。

2. HyperScaler CDS risk 07/28

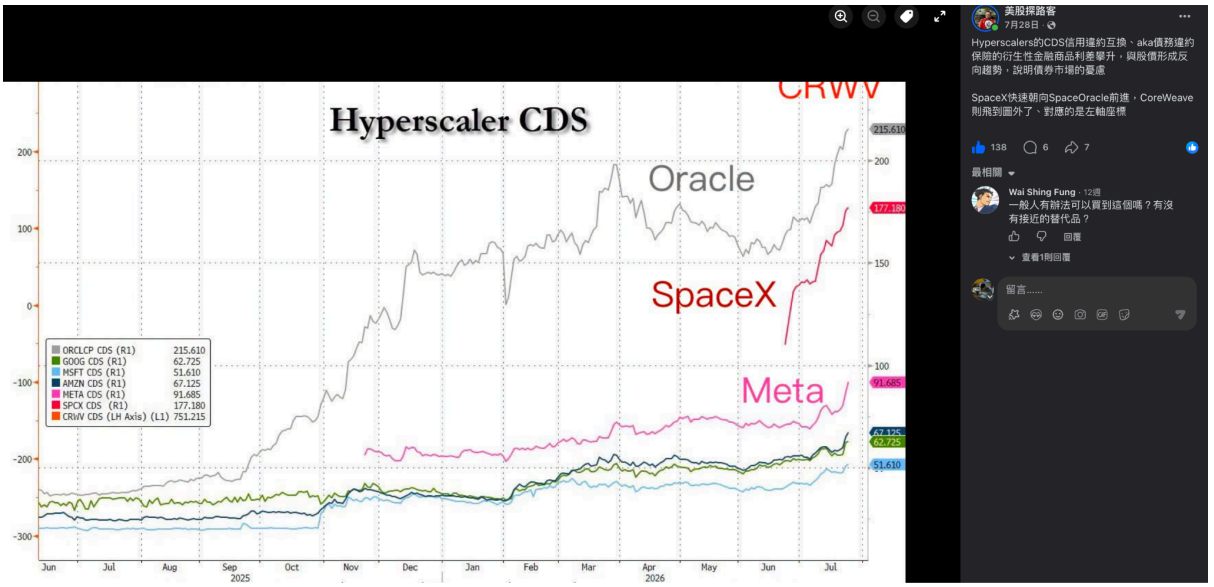

3. Hyperscaler debt and bond issuance 0714

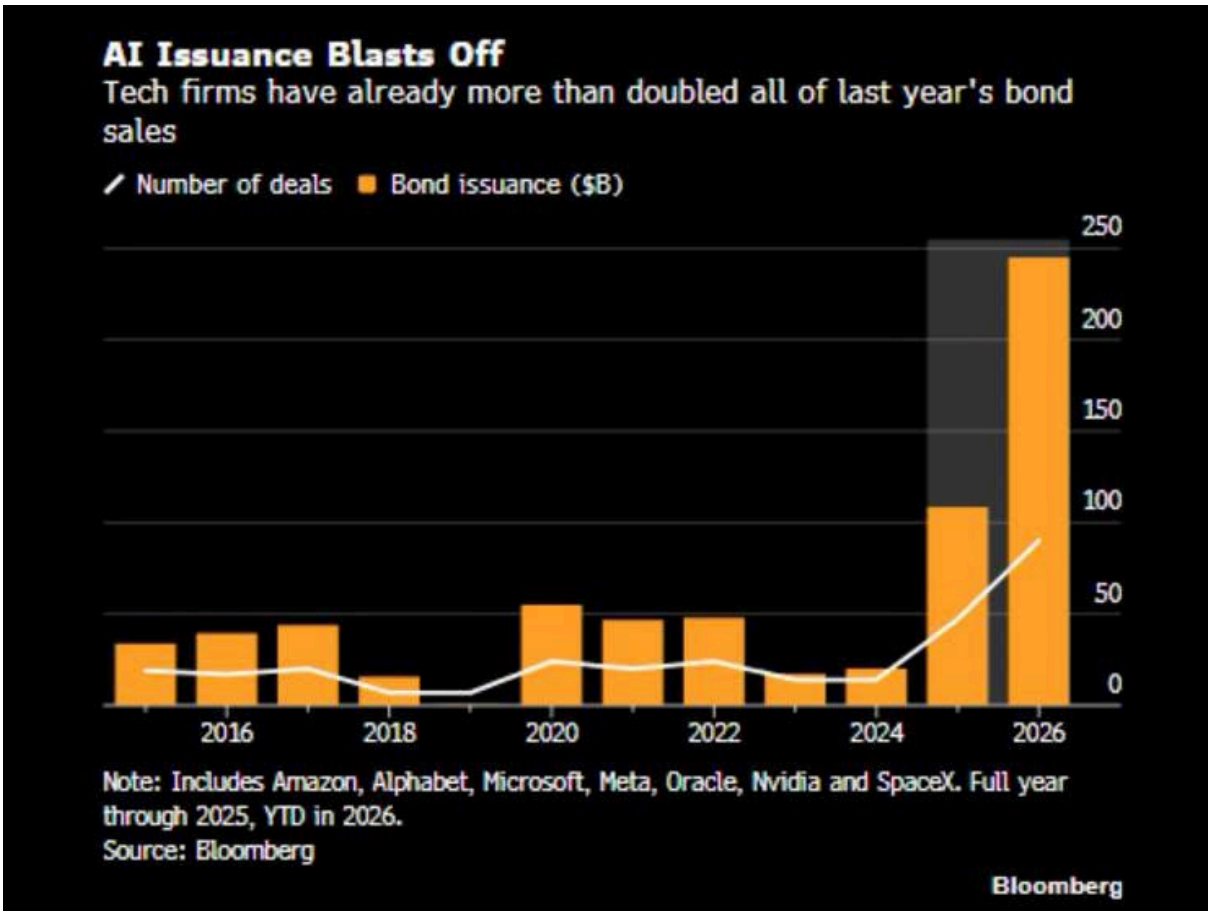

4. Oracle Debt risk 2025/11/18

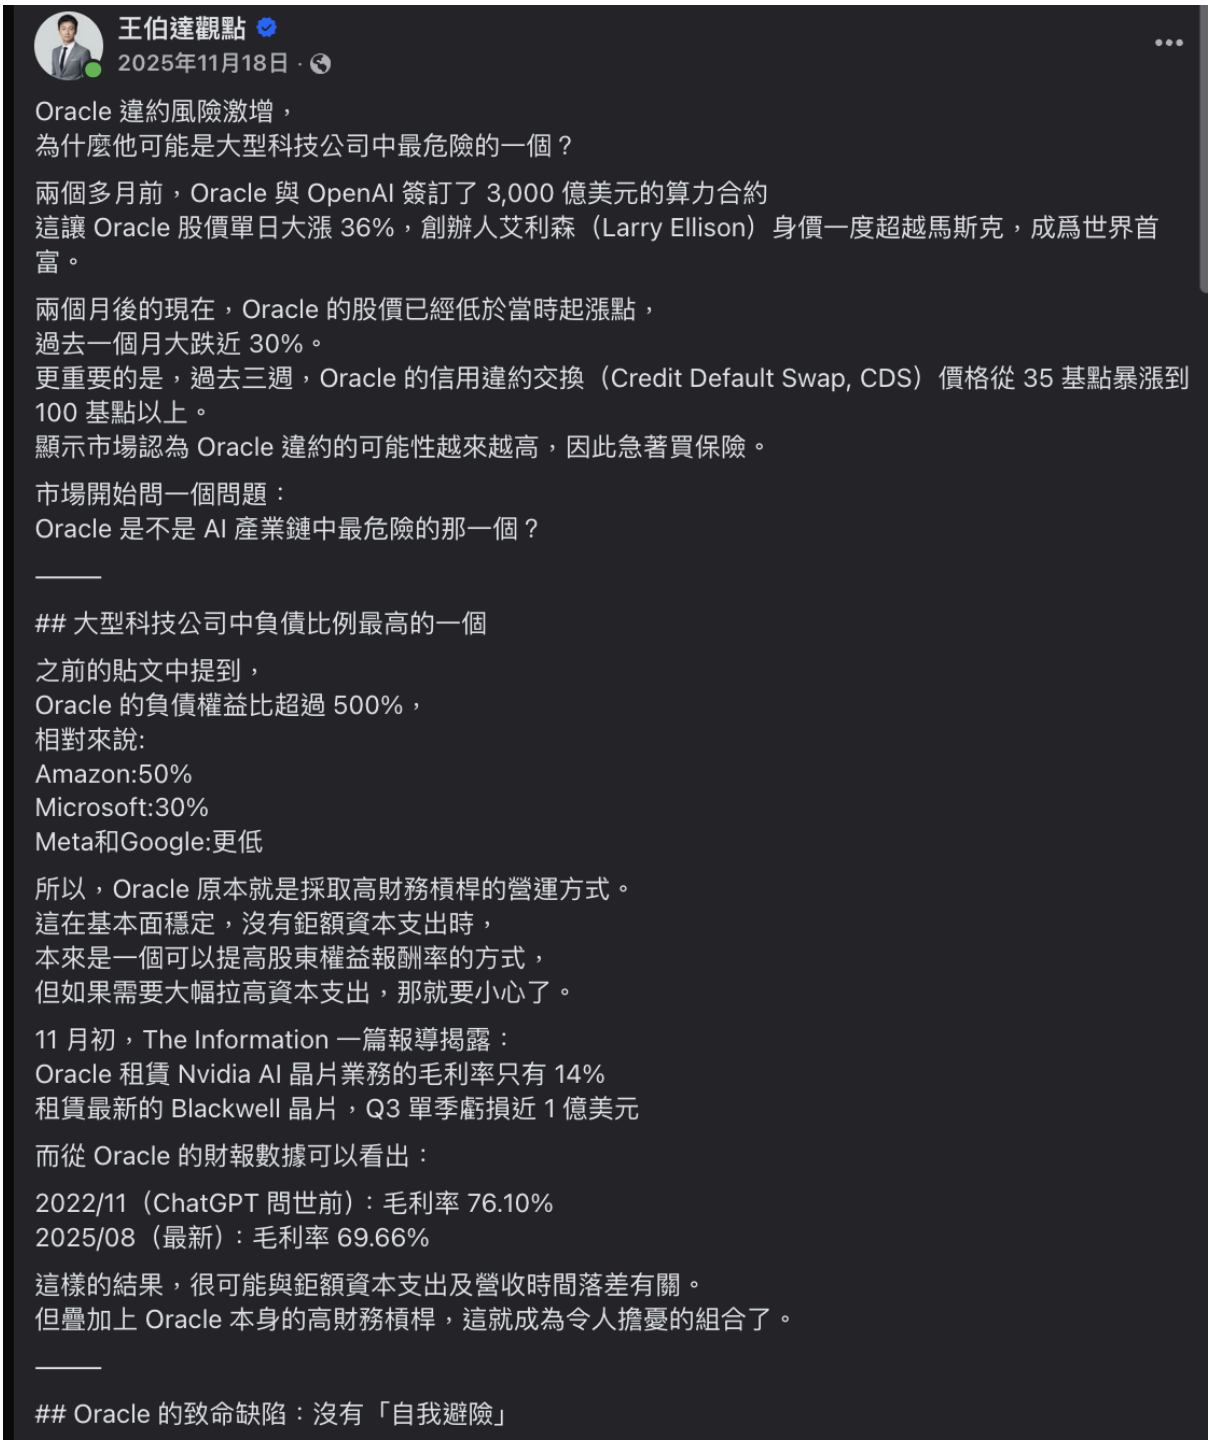

王伯達觀點
2025年11月18日 ·

Oracle 違約風險激增，
為什麼他可能是大型科技公司中最危險的一個？

兩個多月前，Oracle 與 OpenAI 簽訂了 3,000 億美元的算力合約
這讓 Oracle 股價單日大漲 36%，創辦人艾利森（Larry Ellison）身價一度超越馬斯克，成爲世界首富。

兩個月後的現在，Oracle 的股價已經低於當時起漲點，
過去一個月大跌近 30%。
更重要的是，過去三週，Oracle 的信用違約交換（Credit Default Swap, CDS）價格從 35 基點暴漲到 100 基點以上。
顯示市場認為 Oracle 違約的可能性越來越高，因此急著買保險。

市場開始問一個問題：
Oracle 是不是 AI 產業鏈中最危險的那一個？

———

大型科技公司中負債比例最高的一個

之前的貼文中提到，
Oracle 的負債權益比超過 500%，
相對來說:
Amazon:50%
Microsoft:30%
Meta和Google:更低

所以，Oracle 原本就是採取高財務槓桿的營運方式。
這在基本面穩定，沒有鉅額資本支出時，
本來是一個可以提高股東權益報酬率的方式，
但如果需要大幅拉高資本支出，那就要小心了。

11 月初，The Information 一篇報導揭露：
Oracle 租賃 Nvidia AI 晶片業務的毛利率只有 14%
租賃最新的 Blackwell 晶片，Q3 單季虧損近 1 億美元

而從 Oracle 的財報數據可以看出：

2022/11（ChatGPT 問世前）：毛利率 76.10%
2025/08（最新）：毛利率 69.66%

這樣的結果，很可能與鉅額資本支出及營收時間落差有關。
但疊加上 Oracle 本身的高財務槓桿，這就成為令人擔憂的組合了。

———

Oracle 的致命缺陷：沒有「自我避險」

5.